




RÉPUBLIQUE DU BÉNIN

MINISTÈRE DE L'ENSEIGNEMENT SUPÉRIEUR ET DE
LA RECHERCHE SCIENTIFIQUE



UNIVERSITÉ NATIONALE DES SCIENCES, TECHNOLOGIES,
INGÉNIERIE ET MATHÉMATIQUES (UNSTIM) D'ABOMEY

ECOLE NATIONALE SUPÉRIEURE DE GÉNIE MATHÉMATIQUE ET MODÉLISATION

MÉMOIRE

POUR L'OBTENTION DU DIPLOME D'INGÉNIEUR DE CONCEPTION

Spécialité : **Mathématiques Appliquées et Modélisation**

Option : **Modélisation Aléatoire, Statistique et Finance (MASF)**

**Gestion dynamique de portefeuille d'actions basée sur les copules et le
Reinforcement Learning (Apprentissage par renforcement) avec minimisation du
risque extrême (CVaR)**

Présenté par :
Naofal AKANHO

Sous la supervision de :
Dr (MC) Henoc SOUDE
Enseignant-Chercheur à l'IMSP/UAC
Maître de Conférences des Universités du CAMES

Sous l'encadrement de :
Dr (MC) Aliou MOUSSA DJIBRIL
Enseignant-Chercheur à l'UNSTIM d'Abomey
Maître de Conférences des Universités du CAMES

Soutenu à Abomey, le
Composition du jury

Année académique 2024- 2025

L'Ecole Nationale Supérieure de Génie Mathématique et Modélisation (ENSGMM) n'entend donner aucune approbation aux opinions émises dans ce document. Les raisonnements et arguments reviennent donc à l'auteur.

Approbation

Nous certifions que le présent mémoire a été réalisé par l’auteur et exempt de tout plagiat. Il est arrivé à terme et peut être soutenu devant un jury.

Abomey, le

Signatures

Encadreur :

Superviseur :

Dr Aliou MOUSSA DJIBRIL

Dr Henoc SOUDE

DEDICACE

« *Dédicace* »

À la mémoire de ma tendre mère [Feue Mme SADIKOU Nanan Aïcha](#), dont l'amour, les sacrifices et les prières continuent d'éclairer ma route.

REMERCIEMENTS

Je rends avant tout grâce à Allah, Le Tout-Puissant et Le Miséricordieux, qui m'a accordé la santé, la force et la persévérance nécessaires pour mener à bien ce travail.

Je tiens à exprimer toute ma reconnaissance et mon amour à **mon père, AKANHO Rachidi**, pour son soutien moral, ses encouragements constants et ses précieux conseils.

J'exprime ma profonde gratitude à :

- **Prof. Edmond Codjo ADJOVI**, Recteur de l'UNSTIM, pour son ouverture d'esprit et son engagement constant en faveur de l'excellence académique ;
- Mon encadreur, le **Dr (MC) MOUSSA DJIBRIL Aliou**, Directeur de l'ENSGMM, pour son accompagnement, sa disponibilité, sa patience et ses orientations pertinentes.
- Mon superviseur, le **Dr Henoc SOUDE**, pour ses conseils avisés et sa disponibilité ;
- Monsieur **Adiss OREDOLA** et à Madame **Nadège LEKE**, Directeurs de FINFORM Conseils, pour m'avoir permis d'effectuer mon stage dans un environnement propice à l'apprentissage, et pour leurs encouragements, leurs conseils avisés ainsi que leur soutien constant tout au long de cette expérience ;
- Monsieur **BOKO Karel** et à Monsieur **MENSAH Marcaut** pour leur encadrement technique et leur disponibilité ;
- Tous les enseignants de l'ENSGMM, pour la qualité de leur enseignement et leur dévouement envers les étudiants ;
- Tout le personnel administratif de l'ENSGMM, pour leur soutien et leur assistance tout au long de mon parcours académique ;
- Monsieur **AVOCE Serge** pour son aide précieuse dans la mise au point de ce document, notamment à travers le rappel de la méthodologie de rédaction d'un mémoire, son soutien constant et ses conseils avisés.
- Mes frères et sœurs, pour leur amour, leur soutien indéfectible, leurs encouragements constants et leur présence rassurante tout au long de mon parcours académique et personnel.
- Toute l'équipe de FINFORM Conseils pour leur accueil chaleureux, leur soutien et les échanges enrichissants tout au long de mon stage ;
- Mes camarades de promotion pour leur soutien moral et les moments de partage durant notre parcours académique ;
- Monsieur le président et les membres du jury, pour l'honneur qu'ils me font en évaluant ce travail et dont les remarques constructives contribueront à son amélioration.

LISTE DES ABRÉVIATIONS

UNSTIM	Université N ationale des S ciences, T echnologies, I ngénierie et M athématiques
ENSGMM	École N ationale S upérieure de G énie M athématique et de M odélisation
INSPEI	Institut N ational S upérieur, des classes P réparatoires aux d'Études d'Ingénieur
BRVM	Bourse R égionale des V aleurs M obilières
UEMOA	Union É conomique et M onétaire O uest- A fricaine
QQ-plot	Q uantile- Q uantile Plot
VaR	V alue a t R isk (Valeur à Risque)
CVaR	C onditional V alue a t R isk (Expected Shortfall / Conditional Tail Expectation)
ES	E xpected S hortfall
EVar	E ntropic V alue-at- R isk
RL	R einforcement L earning (Apprentissage par renforcement)
DRL	D ep R einforcement L earning (Apprentissage par renforcement profond)
MDP	M arkov D ecision P rocess (Processus de décision de Markov)
SARSA	S tate- A ction- R eward- S tate- A ction (État-Action-Récompense-État-Action)
DQN	D ep Q - N etwork
DDQN	D ouble D ep Q N etwork (Réseau Q double profond)
PPO	P roximal P olicy O ptimization
DDPG	D ep D eterministic P olicy G radient
A2C	A ctor- C ritic
A3C	A synchronous A dvantage A ctor C ritic
LSTM	L ong S hort T erm M emory
KDE	K ernel D ensity E stimation
WCVar	W orst- C ase Conditional Value-at-Risk
C-vine	C anonical vines
D-vine	D rawable vines
SAC	S oft A ctor- C ritic
CAC40	C otation A ssistée en C ontinu (indice boursier de référence d'Euronext Paris regroupant 40 grandes capitalisations françaises)
PER	P rice E arning R atio (Ratio Cours/Bénéfice)
PBR	P rice to B ook R atio (Ratio Cours/Actif Net)
PSR	P rice to S ales R atio (Ratio Cours/Ventes)
PEG	P rice/ E arnings to G rowth (Ratio Cours/Bénéfice ajusté à la croissance)
ROE	R eturn o n E quity (Rentabilité des capitaux propres)
ROA	R eturn o n A ssets (Rentabilité des actifs)
ROI	R eturn o n I nvestment (Retour sur investissement)

S&P500	S tandard & P oor's 500 (indice boursier américain de référence regroupant 500 grandes entreprises)
DAX30	D eutscher A ktienindex 30 (indice allemand élargi à 40 valeurs en 2021)
DJIA30	D ow J ones I ndustrial A verage (indice américain regroupant 30 grandes entreprises)
ETF	E xchange T raded F unds
OPCVM	O rganismes de P lacement C ollectif en V aleurs M obilières
RSI	R elative S trength I ndex (Indice de Force Relative)
SMA	S imple M oving A verage (Moyenne Mobile Simple)
EMA	E xponential M oving A verage (Moyenne Mobile Exponentielle)
MACD	M oving A verage C onvergence D ivergence
BB	B ollinger B ands (Bandes de Bollinger)
BB_Upper	Bande de Bollinger Supérieure
BB_Middle	Bande de Bollinger Centrale
BB_Lower	Bande de Bollinger Inférieure
ADX	A verage D irectional I ndex (Indice Directionnel Moyen)
CCI	C ommodity C hannel I ndex (Indice de Canal des Marchandises)
ATR	A verage T rue R ange (Moyenne de la Vraie Plage)

RÉSUMÉ

Ce mémoire propose une approche de [gestion dynamique de portefeuille d'actions](#) utilisant les [R-vine copules](#) pour modéliser les dépendances complexes entre actifs financiers et l'[algorithme Soft Actor-Critic \(SAC\)](#), choisi pour sa puissance et sa capacité à gérer des actions continues. Chaque semaine, les [k meilleurs actifs](#) de la bourse sont sélectionnés pour constituer un portefeuille, et l'agent SAC détermine l'[allocation optimale](#) en maximisant le rendement attendu tout en minimisant le risque extrême via le CVaR. Les performances de l'agent sont comparées à celles obtenues avec les approches classiques de [Markowitz \(mean-variance\)](#), [Buy & Hold](#) et [Equal Weight](#), montrant que la méthode proposée permet d'améliorer la performance ajustée au risque et d'offrir une meilleure résistance aux chocs extrêmes du marché, démontrant ainsi l'efficacité d'une stratégie de gestion de portefeuille moderne, robuste et adaptative.

Mots clés : Gestion de portefeuille, R-vine copules, Reinforcement Learning, Soft Actor-Critic, CVaR, Allocation d'actifs, Finance quantitative.

ABSTRACT

Keyword : Portfolio management, R-vine copulas, Reinforcement Learning, Soft Actor-Critic, CVaR, Asset allocation, Quantitative finance.

INTRODUCTION GÉNÉRALE

Contexte et justification

« L'argent ne fait pas le bonheur, mais il y contribue. » Cette maxime populaire illustre à quel point les questions financières occupent une place centrale dans la vie des individus et des sociétés. Depuis toujours, l'homme travaille pour produire de la valeur, sécuriser son avenir et accéder à une certaine liberté. L'argent, au-delà de son rôle d'instrument d'échange, constitue un vecteur de sécurité, d'autonomie et de projection intertemporelle.

Les marchés financiers s'inscrivent dans ce processus de création et de circulation du capital : ils assurent la rencontre entre agents à capacité de financement et agents à besoin de financement (entreprises, États, ménages). Parmi ces marchés, la bourse occupe une place emblématique. Souvent perçue comme un espace spéculatif dominé par le hasard, elle est en réalité un mécanisme d'allocation du capital, où la rationalité économique, l'information et les anticipations interagissent. Comme le souligne Warren Buffett, « le marché est une machine à transférer l'argent des impatients vers les patients », rappelant ainsi que la performance financière est avant tout affaire de discipline et de gestion du risque.

L'histoire des marchés boursiers est jalonnée d'événements extrêmes qui témoignent de leur instabilité structurelle, comme par exemple le krach de 1929 qui a plongé le monde dans la Grande Dépression (GALBRAITH, 1955), le lundi noir d'octobre 1987 où le Dow Jones a chuté de plus de 22 % en une seule journée (ROLL, 1988), la crise financière mondiale de 2008 née de l'effondrement du marché des prêts hypothécaires à risque (subprimes) (AGLIETTA, 2008), ou encore les secousses récentes liées à la pandémie de la COVID-19 en 2020. Ces épisodes rappellent que l'investissement en bourse combine opportunités de gains considérables et risques de pertes extrêmes, rendant la gestion de portefeuille essentielle.

C'est précisément cette dualité entre rendement et risque qui fait de la gestion de portefeuille un enjeu central. Comment investir en bourse de manière rationnelle ? Comment répartir ses ressources entre différents actifs pour optimiser le rendement attendu tout en maîtrisant le risque encouru ? Ces interrogations, au cœur de la théorie financière moderne, s'inscrivent dans une problématique plus large : celle du choix rationnel sous incertitude, étudiée depuis longtemps par la théorie microéconomique du consommateur.

Dans ce cadre, l'investisseur peut être assimilé à un agent rationnel, cherchant à maximiser son utilité espérée en arbitrant entre risque et rendement (NEUMANN et MORGENSTERN, 1944). Cette logique de choix rationnel, initialement formalisée en microéconomie, constitue le fondement de la théorie moderne du portefeuille (MARKOWITZ, 1952). Markowitz formalise mathématiquement le compromis rendement–risque, introduit le principe de diversification et définit la frontière efficiente, identifiant les portefeuilles offrant le meilleur rendement pour un niveau de risque donné.

Malgré sa portée conceptuelle, le modèle moyenne–variance repose sur des hypothèses restrictives : normalité des rendements ((MANDELROT, 1963)), symétrie du risque et parfaite connaissance des paramètres ((MERTON, 1980; CHOPRA et ZIEMBA, 1993; MICHAUD, 1989)). Ces limites entraînent des portefeuilles instables et parfois inefficaces hors échantillon, notamment en période de crises financières, où les corrélations entre actifs évoluent brutalement.

Pour pallier ces limites, des modèles d'équilibre comme le MEDAF (SHARPE, 1964; LINTNER, 1965) ou les modèles multifactoriels de (FAMA et FRENCH, 1993; FAMA et FRENCH, 2015) et (CARHART, 1997) relient le rendement attendu d'un actif à son exposition à des facteurs de risque systématiques. Le modèle (BLACK et LITTERMAN, 1992) permet, quant à lui, d'intégrer les vues subjectives de l'investisseur pour améliorer la stabilité des allocations.

Cependant, ces approches restent essentiellement statiques et linéaires, incapables de capturer les dépendances extrêmes et les dynamiques temporelles des marchés. Les crises récentes ont montré que les relations entre actifs deviennent non linéaires et asymétriques en période de stress. C'est pourquoi les approches modernes font appel à des outils capables d'apprendre et d'adapter les allocations en temps réel, comme les copules ((SKLAR, 1959)) pour modéliser les dépendances extrêmes, et l'apprentissage par renforcement pour une gestion dynamique et adaptative des portefeuilles.

But de la recherche

Le but de cette recherche est de contribuer à l'amélioration des stratégies de gestion de portefeuille sur les marchés financiers, en proposant une approche innovante qui combine des techniques modernes d'intelligence artificielle et des modèles statistiques avancés de dépendance. L'objectif ultime est de concevoir un cadre de décision permettant aux investisseurs d'allouer leurs ressources de manière plus rationnelle et robuste, notamment dans des contextes marqués par une forte incertitude et des risques extrêmes. Cette étude vise ainsi à réduire l'écart entre la théorie académique et les pratiques de gestion, tout en mettant en lumière les spécificités des marchés financiers africains, et en particulier ceux de la BRVM.

Problème et questions de recherche

La problématique centrale de ce travail est la suivante :

La problématique centrale de ce travail consiste à concevoir une stratégie d'allocation dynamique de portefeuille d'actions intégrant explicitement la modélisation des dépendances extrêmes à l'aide des copules. Elle interroge également la manière dont la minimisation de la CVaR, combinée à un agent d'apprentissage par renforcement, peut permettre une gestion optimale du risque extrême et une adaptation efficace aux évolutions rapides du marché.

Objectifs du mémoire

Objectif général

L'objectif est de développer et d'implémenter une stratégie de gestion dynamique de

portefeuille d'actions.

Objectif spécifiques

1. **Modéliser la dépendance extrême entre actifs financiers** à l'aide de copules adaptées et définir des marges appropriées pour chaque actif afin de capturer les co-mouvements significatifs en période de crise.
2. **Développer et entraîner un agent d'apprentissage par renforcement** avec une fonction de récompense intégrant la minimisation de la CVaR, pour orienter l'allocation vers une gestion robuste du risque extrême.
3. **Évaluer la performance et la robustesse du modèle proposé** à travers des simulations et des données historiques, en comparaison avec des approches classiques, et analyser la sensibilité face aux chocs extrêmes et aux variations des paramètres de dépendance.

Limites de l'étude

Cette étude présente plusieurs limites qu'il convient de signaler afin d'interpréter les résultats avec prudence.

Tout d'abord, l'analyse se concentre sur un seul algorithme de renforcement, le Soft Actor-Critic (SAC). Bien que SAC soit particulièrement adapté aux espaces d'action continus et à l'apprentissage stable, d'autres modèles de renforcement learning pourraient offrir des performances différentes ou mieux adaptées aux spécificités de la BRVM tels que le Deep Deterministic Policy Gradient (DDPG), le Proximal Policy Optimization (PPO) ou le Twin Delayed DDPG (TD3). L'utilisation d'un seul modèle limite donc la comparabilité et la généralisation des résultats, et pourrait masquer des stratégies plus performantes adaptées à ce marché.

Ensuite, l'étude se limite à la BRVM, ce qui constitue une seconde limite importante. Les caractéristiques propres à cette bourse (liquidité, volatilité, structure des actifs) peuvent influencer la performance des modèles étudiés. Les résultats obtenus ne sont donc pas nécessairement transposables à d'autres marchés africains ou internationaux, et l'efficacité des stratégies proposées pourrait varier significativement dans d'autres contextes.

Enfin, l'étude n'a pas exploré l'impact de variations des hyperparamètres ou de la structure des réseaux neuronaux sur la performance du SAC. De même, l'application combinée de modèles dynamiques et de copules pour capturer les dépendances extrêmes est évaluée sur un ensemble limité de données historiques, ce qui restreint la robustesse statistique des conclusions.

Ces limites ouvrent des perspectives intéressantes pour des travaux futurs, notamment la comparaison de plusieurs modèles de renforcement learning sur la BRVM et d'autres marchés, l'optimisation des hyperparamètres et l'intégration de contraintes de marché plus réalistes.

Résultats attendus de l'étude et cibles

Les résultats attendus incluent des portefeuilles plus robustes face aux chocs extrêmes et à la volatilité locale, ainsi qu'une évaluation comparative démontrant les gains en termes de rendement ajusté au risque et de diversification par rapport aux approches classiques.

Ces travaux s'adressent aux investisseurs individuels et institutionnels, aux gestionnaires de fonds et aux chercheurs souhaitant exploiter des méthodes avancées pour la gestion dynamique de portefeuille sur les marchés africains.

Nouveauté de l'étude

La présente étude se distingue par plusieurs contributions. Elle propose un cadre unifié combinant des mesures de risque robustes, des modèles avancés de dépendance et des techniques d'intelligence artificielle pour la gestion de portefeuille, une approche encore peu explorée dans la littérature. Elle applique cette méthodologie aux données de la BRVM, un marché africain encore largement sous-étudié, alors que la majorité des travaux existants se concentrent sur les marchés développés ou émergents non africains. Enfin, cette étude vise à fournir un outil de gestion plus robuste et réaliste, capable de tenir compte à la fois des spécificités structurelles telles que la liquidité limitée, la volatilité élevée, la concentration sectorielle et les corrélations atypiques entre actifs et des contraintes pratiques incluant les frais de transaction élevés, la réglementation locale, la disponibilité et la qualité des données, ainsi que les limitations liées aux infrastructures de marché propres aux marchés financiers africains.

Structure du mémoire

Le mémoire sera structuré en trois chapitres principaux. Dans le chapitre 1, nous présenterons les concepts théoriques et effectuerons une revue critique de la littérature, en mettant en évidence ce qui a déjà été fait, les méthodologies employées et les résultats obtenus, tout en soulignant les limites et les lacunes des études existantes. Dans le chapitre 2, nous décrirons les jeux de données, les outils utilisés ainsi que les méthodes appliquées pour développer et tester le modèle. Dans le chapitre 3, nous présenterons les résultats et les discussions à la lumière de la littérature existante.

Enfin, dans la conclusion, nous récapitulerons les principales contributions du travail et proposerons des perspectives de recherche.

CADRE THÉORIQUE DE L'ÉTUDE

Contenu

1.1	Introduction	5
1.2	Clarification conceptuelle	6
1.2.1	Définitions	6
1.3	Revue de Litterature	22
1.4	Conclusion	25

Figures

1.1	Fonction de valeur d'état $V_\pi(s)$ (extrait de (RAMBOUR, 2023))	12
1.2	Fonction de valeur d'action $Q_\pi(s, a)$ (extrait de (RAMBOUR, 2023))	13
1.3	Fonction de valeur état action $V_\pi(s, a)$ (extrait de (RAMBOUR, 2023))	14

Tableaux

1.1	Types d'apprentissage automatique	9
-----	---	---

1.1 Introduction

Le premier chapitre de ce mémoire constitue le fondement théorique de l'étude et se propose d'apporter une clarification approfondie des concepts centraux relatifs à la gestion dynamique de portefeuille d'actions, à la modélisation des dépendances extrêmes via les copules, ainsi qu'à l'apprentissage par renforcement appliqué à la finance. Il s'agit, à travers l'examen des définitions, de circonscrire le cadre conceptuel de la recherche. Une telle clarification conceptuelle est indispensable pour établir un langage scientifique commun, assurer la rigueur terminologique et servir de référence tout au long du mémoire.

Dans un second temps, ce chapitre propose une revue de la littérature portant sur les approches théoriques et empiriques existantes. L'analyse des modèles classiques et contemporains d'allocation de portefeuille, des méthodes de gestion du risque extrême et des techniques

d'intelligence artificielle appliquées à la finance permettra de dégager à la fois les apports significatifs et les limites méthodologiques de ces travaux. Cette synthèse critique vise à identifier les lacunes encore présentes dans la littérature, à justifier l'intérêt scientifique de la démarche adoptée et à poser les bases solides pour la formulation des hypothèses de recherche qui guideront la conception et le développement du modèle étudié dans ce mémoire.

1.2 Clarification conceptuelle

Nous voulons à travers cette clarification définir les termes que nous allons utiliser dans ce travail.

1.2.1 Définitions

Portefeuille

Un portefeuille est un ensemble structuré d'actifs financiers détenus simultanément par un investisseur. Il rassemble diverses catégories d'investissement (actions, obligations, liquidités, etc.) dans le but de diversifier les sources de rendement et de répartir les risques associés.

Selon la stratégie adoptée, un portefeuille peut être monoproduit, composé exclusivement d'un seul type d'actifs, par exemple uniquement des actions, ou diversifié, intégrant plusieurs classes d'actifs pour réduire la volatilité globale et mieux gérer le risque. Le choix entre ces types de portefeuille dépend des objectifs (croissance du capital à long terme, génération de revenus réguliers), de la tolérance au risque (investisseurs prudents privilégiant la sécurité, investisseurs audacieux recherchant des gains élevés) et de l'horizon d'investissement de l'investisseur (court terme pour des besoins rapides, long terme pour la préparation de la retraite ou la constitution d'un patrimoine).

Actions

Une action représente une part de propriété dans une entreprise. En détenant une action, l'investisseur devient copropriétaire de la société et peut bénéficier de ses résultats financiers, sous forme de dividendes ou de plus-values. Les actions sont négociées sur les marchés financiers, et leur valeur fluctue en fonction de la performance de l'entreprise et des conditions du marché.

Gestion de portefeuille

La gestion de portefeuille désigne l'ensemble des processus et décisions visant à sélectionner, ajuster et surveiller la composition des actifs détenus. Elle cherche à optimiser l'équilibre entre rendement attendu et risque, en fonction des contraintes, des objectifs et du profil de l'investisseur. Elle comporte principalement :

- **Définition des objectifs** : déterminer les attentes en termes de rendement, la tolérance au risque, l'horizon d'investissement ainsi que les contraintes spécifiques (liquidité, réglementaires, éthiques).
- **Sélection des actifs** : identifier et choisir les instruments financiers (actions, obligations, etc.) adaptés aux objectifs et contraintes définis.

- **Allocation d'actifs** : répartir le capital global entre différentes classes d'actifs, selon le profil de risque et l'horizon d'investissement, dans une démarche stratégique ou tactique.
- **Optimisation de portefeuille** : appliquer des modèles mathématiques pour déterminer la combinaison précise d'actifs qui maximise le rendement attendu pour un niveau de risque donné, ou minimise le risque pour un rendement ciblé.
- **Mise en œuvre** : exécuter les décisions d'investissement en achetant ou vendant les actifs sélectionnés selon la composition optimale déterminée.
- **Suivi et rééquilibrage** : surveiller régulièrement la performance du portefeuille et ajuster sa composition en réponse aux évolutions du marché, des objectifs ou du profil de risque.

Mesures de risque

En finance, évaluer et gérer le risque est une étape fondamentale pour protéger le capital investi et assurer la pérennité des placements. Les marchés financiers sont marqués par une forte incertitude, où les prix des actifs peuvent varier rapidement en raison de facteurs économiques, politiques ou exogènes imprévus. Un investisseur est ainsi exposé à différents types de risques : la volatilité, qui traduit les fluctuations régulières des prix ; les pertes extrêmes, liées à des événements rares mais aux conséquences sévères ; et les chocs systémiques affectant simultanément plusieurs actifs.

Dans ce contexte, disposer d'indicateurs de risque fiables est indispensable pour quantifier ces menaces, anticiper les pertes potentielles, et prendre des décisions éclairées. Ces mesures permettent non seulement de limiter l'exposition aux risques, mais aussi d'optimiser la composition du portefeuille en fonction du profil de l'investisseur, conciliant rendement attendu et tolérance au risque.

On distingue plusieurs indicateurs principaux dont :

1. Mesures statistiques classiques

• Variance et Écart-type

— Variance

Elle mesure la dispersion des rendements par rapport à leur moyenne. Plus la variance est élevée, plus les rendements fluctuent, indiquant un risque accru.

$$\sigma^2 = \frac{1}{n} \sum_{t=1}^n (R_t - \bar{R})^2 \quad (1.1)$$

où :

- * R_t : rendement de l'actif à la période t (ou instant t)
- * $\bar{R}$: rendement moyen sur toutes les périodes considérées
- * σ^2 : variance des rendements

Cette mesure reflète le risque global d'un actif ou d'un portefeuille en prenant en compte toutes les fluctuations, qu'elles soient positives ou négatives.

— Écart-type

L'écart-type correspond à la racine carrée de la variance. Exprimé dans la même unité que le rendement, il offre une interprétation plus intuitive de la volatilité.

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{n} \sum_{t=1}^n (R_t - \bar{R})^2} \quad (1.2)$$

Une valeur élevée de l'écart-type indique une forte volatilité et donc un risque important. Cependant, ces mesures considèrent la volatilité totale comme indicateur unique du risque, sans distinguer les fluctuations favorables (gains) des défavorables (pertes). Cela peut conduire à sous-estimer la perception réelle du risque par les investisseurs, souvent plus sensibles aux pertes qu'aux gains.

2. Mesures centrées sur les pertes

Le Downside Risk est une approche alternative qui se concentre exclusivement sur les fluctuations défavorables des rendements, c'est-à-dire celles situées en dessous d'un seuil de référence (souvent le rendement moyen ou un rendement cible). Contrairement à la variance et à l'écart-type, qui mesurent la volatilité totale, cette approche vise à évaluer le risque réel de perte auquel un investisseur est exposé.

Sémivariance

L'une des mesures les plus utilisées du Downside Risk est la sémivariance, qui calcule la dispersion uniquement des rendements inférieurs au seuil de référence. Elle capture ainsi la variabilité défavorable, correspondant au risque baissier.

$$\text{SemiVar} = \frac{1}{n} \sum_{t=1}^n (\min(0, R_t - \bar{R}))^2 \quad (1.3)$$

En ne prenant en compte que les fluctuations négatives, la sémivariance oriente l'analyse vers une gestion du risque centrée sur la protection du capital. Elle est particulièrement adaptée aux investisseurs averses au risque, qui cherchent à limiter les pertes plutôt qu'à réduire la volatilité totale.

3. Mesures de risque extrême

— La Value-at-Risk (VaR)

La VaR est une mesure de risque largement utilisée par les institutions financières et les régulateurs (notamment dans les accords de Bâle) pour sa simplicité d'interprétation. Elle estime la perte maximale qu'un portefeuille peut subir sur un horizon donné, avec un niveau de confiance α , en supposant des conditions de marché normales.

Formellement, si X désigne la variable aléatoire des pertes, la VaR est définie comme le quantile d'ordre α de la distribution de X :

$$\text{VaR}_\alpha = \inf\{x \in \mathbb{R} \mid F_X(x) \geq \alpha\}. \quad (1.4)$$

Cette définition implique que :

$$\mathbb{P}(X \leq \text{VaR}_\alpha) = \alpha \quad \text{et donc} \quad \mathbb{P}(X \geq \text{VaR}_\alpha) = 1 - \alpha, \quad (1.5)$$

c'est-à-dire qu'avec une probabilité α la perte reste inférieure ou égale à la VaR, et qu'elle ne la dépasse qu'avec une probabilité $1 - \alpha$.

— CvaR

Elle est une mesure de risque complémentaire à la VaR, qui prend en compte non seulement le seuil de perte mais aussi la moyenne des pertes extrêmes dépassant ce seuil. Elle est particulièrement utile pour évaluer le risque dans la queue de la distribution des pertes.

Formellement, pour un niveau de confiance α et une variable aléatoire X représentant les pertes, la CVaR est définie par :

$$\text{CVaR}_\alpha(X) = \mathbb{E}[X \mid X \geq \text{VaR}_\alpha(X)], \quad (1.6)$$

c'est-à-dire la perte moyenne conditionnelle lorsque la perte dépasse la VaR.

La CVaR fournit ainsi une estimation plus prudente du risque, car elle tient compte de l'ampleur des pertes extrêmes et non seulement de leur seuil.

Évolution des mesures de risque

Les modèles classiques, bien que fondamentaux, restent limités par leurs hypothèses sur la distribution des rendements et leur sensibilité aux estimations de paramètres. Les développements récents se sont ainsi orientés vers des approches intégrant des mesures de risque asymétriques, des distributions non normales et des outils d'optimisation plus robustes. Dans cette optique, (MARKOWITZ, 1959) introduit la semi-variance, centrée sur les écarts négatifs par rapport à l'espérance, afin de mieux refléter l'aversion des investisseurs face aux pertes tout en conservant l'esprit du cadre initial. Pour capturer les caractéristiques empiriques des rendements, souvent asymétriques et à queues épaisses, des modèles à moments supérieurs ((KRAUS et LITZENBERGER, 1976), (HWANG et SATCHELL, 1999) ou (HARVEY et SIDDIQUE, 2000)) intègrent l'asymétrie et la kurtosis, pénalisant les portefeuilles exposés à des distributions fortement biaisées ou concentrées. Sur un plan opérationnel, la VaR, popularisée par JP Morgan dans les années 1994, offre un indicateur simple du seuil de perte maximal à un niveau de confiance donné, mais son manque de cohérence et de convexité limite son efficacité en optimisation ((PHILIPPE ARTZNER et HEATH, 1999), (SZEGÖ, 2002)). Pour y remédier, (ROCKAFELLAR et URYASEV, 2000) proposent la Conditional Value-at-Risk (CVaR), qui mesure la perte moyenne au-delà du seuil critique et respecte les propriétés de cohérence, renforçant sa pertinence face aux distributions non normales. D'autres mesures plus récentes, telles que la Buffered Probability of Exceedance (bPOE) ((MAFUSALOV et URYASEV, 2018)), combinent probabilité et sévérité des pertes extrêmes dans un cadre convexe et différentiable.

Machine Learning

L'apprentissage automatique, ou Machine Learning, constitue une branche essentielle de l'intelligence artificielle dont l'objectif est de développer des algorithmes capables d'extraire des régularités à partir de données et d'adapter leur comportement sans intervention humaine explicite. On distingue classiquement deux grandes approches : l'apprentissage symbolique, fondé sur des règles logiques explicites, et l'apprentissage par expérience, où les modèles apprennent directement des exemples. Ce dernier est au cœur du Machine Learning, qui se divise principalement en trois paradigmes : l'apprentissage supervisé, où l'algorithme apprend à partir de données étiquetées ; l'apprentissage non supervisé, centré sur la découverte de structures cachées dans des données brutes ; et l'apprentissage par renforcement, où un agent apprend par essais et erreurs à interagir avec un environnement.

TABLE 1.1 – Types d'apprentissage automatique

Apprentissage supervisé	Apprentissage non supervisé	Apprentissage par renforcement
Entraînement avec des données étiquetées (entrée + sortie)	Entraînement avec des données sans étiquettes	Apprentissage par interaction avec l'environnement et retour d'information (récompense / pénalité)

À ces paradigmes s'ajoutent des formes hybrides telles que l'apprentissage semi-supervisé ou auto-supervisé, de plus en plus utilisées dans les systèmes modernes.

Reinforcement Learning

L'apprentissage par renforcement désigne un cadre dans lequel un agent apprend à agir dans un environnement en recevant des signaux de récompense ou de pénalité. À travers l'exploration, il ajuste progressivement sa stratégie afin de maximiser les gains obtenus sur le long terme.

Contrairement à l'apprentissage supervisé, le RL ne repose pas sur des exemples avec réponses correctes. L'agent doit découvrir lui-même, par essais et erreurs, quelles actions sont bénéfiques. De plus, les conséquences de ses décisions peuvent se manifester plusieurs étapes plus tard, ce qui rend le problème fondamentalement temporel.

Un problème de RL implique généralement :

- **Un agent** (le décideur) : Il peut être un robot, un logiciel ou tout autre système). Il prend les décisions en fonction de l'environnement.
 - **Un environnement** : le système avec lequel l'agent interagit, fournissant à chaque action un nouvel état et une récompense. Il peut être déterministe ou stochastique (inclure de l'aléatoire).
 - **Des états** $s \in S$ qui représentent les différentes situations, configurations ou conditions possibles dans lesquelles l'agent peut se trouver dans l'environnement.
L'état représente la situation actuelle de l'environnement dans lequel l'agent opère.
 - **Des observations** $o \in O$: qui représentent l'information accessible à l'agent sur l'état de l'environnement.
Une observation peut être partielle, ne montrant qu'une partie de l'état, ou complète, fournissant une vue totale de la situation actuelle. Elles permettent à l'agent de prendre des décisions même sans connaître l'état complet.
 - **Des actions** $a \in A$ que l'agent peut entreprendre dans un état donné.
Une action est l'intervention de l'agent sur l'environnement qui change son état. Elle peut être discrète ou continue.
 - **Une reward (récompense)** R qui signale la qualité de l'action effectuée, c'est un signal numérique qui va faire comprendre à l'agent si son action s'avère bénéfique ou pas.
 - **Une politique (policy)** π définissant le comportement de l'agent (c'est-à-dire la règle qui associe une action à chaque état), la manière dont un agent sélectionne ses actions.
- Nous avons :

— **Politique déterministe (deterministic policy)**

Elle est définie comme :

$$\pi : S \rightarrow A \quad (1.7)$$

On associe chaque état à une action unique où l'action entreprise à chaque état est déterminée et représentée par une fonction déterministe :

$$\pi(s) = a \quad (1.8)$$

— **Politique stochastique (stochastic policy)**

On associe à chaque état une distribution de probabilité sur les actions. Elle se matérialise par une nouvelle fonction qui dépend de deux variables :

$$\begin{aligned} \pi : S \times A &\rightarrow [0, 1] \\ \pi(a | s) &\mapsto \mathbb{P}(A_t = a | S_t = s) \end{aligned} \quad (1.9)$$

On la note $\pi(a | s)$ pour notifier que l'action a est conditionnée par l'état s .

- **Un retour** qui représente la somme des récompenses futures attendues (souvent noté $G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots + \gamma^k R_{t+k+1} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$, avec γ le facteur d'actualisation qui contrôle l'importance des récompenses futures par rapport aux récompenses immédiates.).

L'apprentissage par renforcement cherche à résoudre des problèmes où un agent doit prendre des décisions successives dans un environnement incertain et dynamique, afin de maximiser une récompense cumulative. Dans ce cadre, chaque action prise par l'agent n'a pas seulement un effet immédiat : elle influence aussi les états futurs dans lesquels l'agent se trouvera, ainsi que les options et récompenses associées à ces futurs états. Il s'agit donc d'un problème de prise de décision séquentielle, où l'agent doit anticiper les conséquences de ses choix à long terme. Cette dimension temporelle et causale rend nécessaire un formalisme rigoureux pour :

- modéliser les transitions entre états dans le temps,
- représenter l'incertitude sur l'évolution de l'environnement,
- définir clairement les objectifs d'optimisation à long terme.

C'est dans ce contexte qu'intervient le cadre des **processus de décision markoviens** (MDP), qui fournit une base mathématique solide pour formaliser et résoudre ce type de problèmes.

Fondements mathématiques de l'apprentissage par renforcement

Processus de Markov

Un **processus markovien** (ou **chaîne de Markov**) est défini par le couple (S, P) , où :

- S désigne l'ensemble fini des états possibles du système ;
- P est la matrice de transition stochastique associée à S , telle que chaque élément P_{ij} représente la probabilité de transition de l'état $s_i \in S$ vers l'état $s_j \in S$, avec :

$$P_{ij} = \mathbb{P}(X_{t+1} = s_j | X_t = s_i), \quad \forall s_i, s_j \in S. \quad (1.10)$$

Processus de décision de Markov

Un processus de décision markovien (MDP) est défini par le quintuplet :

$$\text{MDP} = (S, A, \mathbf{P}, \mathbf{R}, \gamma) \quad (1.11)$$

où :

- S est l'ensemble des états possibles de l'environnement.
- A est l'ensemble des actions que l'agent peut entreprendre.
- $\mathbf{P}$ est la matrice de transition d'un couple $(s, a) \in S \times A$ vers S
- $\mathbf{R}$ est la récompense moyenne associée à chaque couple état-action

$$R_s^a = \mathbb{E}[R_t | S_t = s, A_t = a] \quad (1.12)$$

- $\gamma \in [0, 1]$ est le facteur d'actualisation qui pondère l'importance des récompenses futures.

Un MDP repose sur la propriété de Markov, qui stipule que la probabilité de transition vers l'état suivant dépend uniquement de l'état actuel et de l'action entreprise, et non des états ou actions passés. Formellement :

$$P_{ss'}^a = \mathbb{P}(S_{t+1} | S_t = s, A_t = a, S_{t-1}, A_{t-1}, \dots) = \mathbb{P}(S_{t+1} = s' | S_t = s, A_t = a) \quad (1.13)$$

Cette propriété permet de simplifier la modélisation et de ne pas stocker tout l'historique. Une fois une politique π fixée, le MDP (S, A, P, R, γ) se ramène à un Processus de Récompense Markovien (MRP) $(S, P^\pi, R^\pi, \gamma)$, où les probabilités de transition et les récompenses sont moyennées selon la politique :

$$P_{ss'}^\pi = \sum_{a \in A} \pi(a | s) P_{ss'}^a \quad (1.14)$$

$$R_s^\pi = \sum_{a \in A} \pi(a | s) R_s^a. \quad (1.15)$$

Cela permet de raisonner sur les fonctions de valeur V^π et Q^π .

Fonctions de valeur et politique optimale

Fonction de valeur d'état

Elle estime la valeur totale que l'agent peut espérer accumuler à partir d'un état spécifique s , sans considérer une action immédiate. Elle représente la quantité de récompense que l'agent s'attend à gagner, en moyenne, en étant dans cet état et en suivant une politique donnée. Cette estimation aide l'agent à comprendre quelles positions ou états dans l'environnement sont les plus bénéfiques sur le long terme. (Source : DataBird, *Reinforcement Learning : L'apprentissage par renforcement*, <https://www.data-bird.co/blog/reinforcement-learning>)

$$V_\pi(s) = \mathbb{E}[G_t | S_t = s] = \mathbb{E}\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s\right] \quad (1.16)$$




FIGURE 1.1 – Fonction de valeur d'état $V_\pi(s)$ (extrait de (RAMBOUR, 2023))

La valeur d'un état sous la politique π est donnée par la relation suivante :

$$V_\pi(s) = \sum_{a \in A} \pi(s, a) q_\pi(s, a) \quad (\text{A.3})$$

Pour plus de détails sur la démonstration complète de cette formule, le lecteur peut se référer à l'Annexe A.1.1.

Fonction valeur d'action

Elle évalue la valeur de prendre une action a dans un état s puis en suivant la politique π . Contrairement à $V_\pi(s)$ $Q_\pi(s, a)$ fournit une mesure de l'efficacité d'une action spécifique dans un état donné. Cela permet à l'agent de juger non seulement le meilleur état à atteindre mais aussi la meilleure action à effectuer dans un état particulier pour maximiser les récompenses futures. (Source : DataBird, *Reinforcement Learning : L'apprentissage par renforcement*, <https://www.data-bird.co/blog/reinforcement-learning>)

$$Q_\pi(s, a) = \mathbb{E}[G_t | s_t = s, a_t = a] \quad (1.17)$$




FIGURE 1.2 – Fonction de valeur d'action $Q_\pi(s, a)$ (extrait de (RAMBOUR, 2023))

La fonction d'action-valeur $Q_\pi(s, a)$ sous une politique π est définie par :

$$q_\pi(s, a) = \sum_{s' \in \mathcal{S}} P(s, a, s') [R(s, a, s') + \gamma V_\pi(s')]. \quad (\text{A.4})$$

Pour plus de détails, le lecteur peut se référer à l'Annexe A.1.1




FIGURE 1.3 – Fonction de valeur état action $V_\pi(s, a)$ (extrait de (RAMBOUR, 2023))

On obtient la formule de valeur de l'état en substituant $q_\pi(s, a)$ dans l'équation (A.3) :

$$V_\pi(s) = \sum_{a \in A} \pi(s, a) \sum_{s' \in S} P(s, a, s') [R(s, a, s') + \gamma V_\pi(s')]. \quad (\text{A.5})$$

Politique optimale

Après avoir introduit les fonctions de valeur $V_\pi(s)$ et $Q_\pi(s, a)$, il est naturel de définir la **politique optimale** π^* . Cette politique permet à l'agent de maximiser la récompense totale attendue depuis chaque état.

On définit la valeur optimale d'un état comme :

$$V^*(s) \equiv \max_{\pi} V^\pi(s) = \max_{a \in A(s)} Q^\pi(s, a), \forall s \in S \quad (1.18)$$

On en déduit l'équation d'optimalité de Bellman pour V :

$$V^*(s) = \max_{a \in A(s)} \sum_{s' \in S} P(s, a, s') [R(s, a, s') + \gamma V^*(s')] \quad (1.19)$$

et l'équation d'optimalité de Bellman pour Q :

$$Q^*(s, a) \equiv \max_{\pi} Q_\pi(s, a) = \sum_{s' \in S} P(s, a, s') [R(s, a, s') + \gamma \max_{a' \in A} Q^*(s', a')] \quad (1.20)$$

Ces valeurs représentent le meilleur résultat attendu que l'agent peut atteindre, respectivement depuis l'état s ou après avoir choisi l'action a . La relation entre V^* et Q^* est donnée par :

$$V^*(s) = \max_a Q^*(s, a) \quad (1.21)$$

ce qui montre que pour connaître la valeur optimale d'un état, il suffit de choisir la meilleure action possible dans cet état.

Ces fonctions permettent de mesurer l'intérêt relatif des états et des actions, et servent de base pour construire la politique optimale π^* :

$$\pi^*(s) = \arg \max_{a \in A} Q_{\pi^*}(s, a) = \arg \max_{a \in A} \sum_{s' \in S} P(s, a, s') [R(s, a, s') + \gamma V^*(s')] \quad (1.22)$$

Algorithmes de résolution des MDP

Les méthodes d'apprentissage par renforcement se distinguent selon que l'agent dispose ou non d'un modèle de l'environnement. On distingue ainsi deux grandes familles : les approches basées sur un modèle (Model-Based) et les approches sans modèle (Model-Free).

• Approches basées sur un modèle (Model-Based)

Dans le cas *Model-Based*, l'agent connaît, ou est capable d'apprendre, la dynamique de l'environnement, c'est-à-dire la fonction de transition $P(s, a, s')$ et la fonction de récompense $R(s, a, s')$. Ces informations permettent de planifier en simulant mentalement les conséquences de différentes actions. Parmi les principales méthodes de planification basées sur un modèle, on distingue deux algorithmes fondamentaux :

— Itération de valeur (Value Iteration)

L'itération de valeur (BELLMAN, 1957) est un algorithme de programmation dynamique qui met à jour directement la fonction de valeur optimale. À chaque étape, on calcule pour chaque état :

$$V_{k+1}(s) = \max_{a \in A} \sum_{s' \in S} P(s, a, s') [R(s, a, s') + \gamma V_k(s')] \quad (1.23)$$

L'algorithme procède en plusieurs étapes :

1. **Initialisation arbitraire** : $V_0(s)$ pour tous les états s .
2. **Mise à jour récursive** : Calcul de $V(s)$ pour tous les états à chaque itération.
3. **Convergence** : Répéter jusqu'à ce que $V(s)$ converge vers $V^*(s)$, la valeur optimale.
4. **Extraction de la politique optimale** :

$$\pi^*(s) = \arg \max_{a \in A} \sum_{s' \in S} P(s, a, s') [R(s, a, s') + \gamma V^*(s')]$$

— Itération de politique (Policy Iteration)

L'itération de politique (HOWARD, 1960) est un algorithme de programmation dynamique qui alterne entre deux étapes :

1. **Évaluation de la politique** : Pour une politique donnée π_k , on calcule sa fonction de valeur en résolvant :

$$V_{\pi_k}(s) = \sum_{s' \in S} P(s, \pi_k(s), s') [R(s, \pi_k(s), s') + \gamma V_{\pi_k}(s')] \quad (1.24)$$

2. **Amélioration de la politique** : On met à jour la politique en choisissant les actions qui maximisent la valeur :

$$\pi_{k+1}(s) = \arg \max_{a \in A} \sum_{s' \in S} P(s, a, s') \left[R(s, a, s') + \gamma V_{\pi_k}(s') \right] \quad (1.25)$$

Ces étapes sont répétées jusqu'à ce que la politique converge vers π^* , la politique optimale.

Bien que puissants, ces algorithmes supposent :

- Un espace d'état/action fini et de taille raisonnable.
- Une connaissance exacte des probabilités de transition et des récompenses.

Dans des environnements complexes (états continus, dynamiques inconnues), ces méthodes deviennent inapplicables.

• **Approches sans modèle (Model-Free)**

Dans le cas **Model-Free**, l'agent n'a pas accès à la dynamique de l'environnement et doit apprendre à partir de l'expérience. Les méthodes sans modèle se concentrent sur l'apprentissage direct des politiques ou des fonctions de valeur à partir des interactions avec l'environnement, par essais et erreurs.

1. **Approches Value-Based**

Les méthodes basées sur la valeur en apprentissage par renforcement (RL) se concentrent sur l'apprentissage de la fonction d'action-valeur $Q(s, a)$, qui mesure la qualité d'une action a dans un état s en termes de récompenses futures cumulatives attendues. La politique optimale est ensuite obtenue en choisissant, pour chaque état, l'action qui maximise $Q(s, a)$.

Un algorithme emblématique de cette approche est le **Q-Learning** (WATKINS et DAYAN, 1992), qui permet d'apprendre directement $Q(s, a)$ sans connaître la dynamique de l'environnement. Cette méthode a été étendue à des environnements complexes grâce à l'apprentissage profond, donnant naissance à des architectures telles que le **Deep Q-Network (DQN)**.

2. **Approches Policy-Based**

Contrairement aux méthodes Value-Based qui estiment la qualité des actions pour en déduire une politique, les approches Policy-Based se concentrent sur l'apprentissage direct d'une politique $\pi_\theta(a|s)$, où θ représente les paramètres de la politique. Cette approche consiste à ajuster directement ces paramètres afin de maximiser la récompense cumulative attendue de l'agent, sans passer par l'estimation explicite des fonctions de valeur.

L'un des principaux avantages des méthodes Policy-Based est leur capacité à traiter des environnements avec des *espaces d'action continus* ou très larges, où les méthodes Value-Based deviennent inefficaces ou instables. De plus, en optimisant directement la politique, ces méthodes peuvent offrir une meilleure stabilité lors de l'apprentissage, en particulier dans les environnements stochastiques ou hautement non linéaires.

Un algorithme emblématique de cette approche est **REINFORCE** (WILLIAMS, 1992), qui utilise la technique du gradient de politique pour mettre à jour les paramètres de la politique proportionnellement à la récompense obtenue.

Ainsi, les approches Policy-Based complètent les méthodes Value-Based en offrant une alternative robuste pour l'apprentissage de politiques optimales, particulièrement dans des environnements complexes ou continus.

3. Approches Actor-Critic

Les méthodes **Actor-Critic** constituent une extension naturelle des approches Policy-Based en combinant l'apprentissage direct d'une politique avec l'estimation d'une fonction de valeur. L'agent est composé de deux entités distinctes :

- **L'Actor** : responsable de la politique $\pi_\theta(a|s)$, qui choisit les actions à exécuter en fonction de l'état courant. Il ajuste ses paramètres pour augmenter la probabilité des actions conduisant à de meilleures récompenses.
- **Le Critic** : estime la qualité d'une action, généralement à travers une fonction $Q(s, a)$. Cette estimation sert de guide pour l'Actor, en indiquant si les actions choisies ont été meilleures ou moins bonnes que prévu.

La principale force de cette architecture réside dans la stabilité et l'efficacité de l'apprentissage : le Critic réduit la variance des mises à jour de la politique en fournissant un signal plus précis sur la qualité des actions, tandis que l'Actor permet de naviguer facilement dans des espaces d'action continus.

Parmi les algorithmes célèbres basés sur cette architecture, on peut citer **A2C/A3C** (Advantage Actor-Critic), **DDPG** (Deep Deterministic Policy Gradient) et **PPO** (Proximal Policy Optimization). Ces méthodes ont démontré leur efficacité dans des environnements complexes tels que les jeux vidéo, la robotique et la gestion de ressources.

Ainsi, les méthodes Actor-Critic exploitent simultanément l'estimation de valeur et l'optimisation directe de la politique, offrant un compromis performant entre stabilité et capacité à traiter des problèmes d'apprentissage par renforcement à grande échelle.

Variable aléatoire

Une variable aléatoire est une fonction qui associe à chaque issue d'une expérience aléatoire un nombre réel. Elle permet de quantifier les résultats incertains afin de les analyser mathématiquement.

Loi de probabilité

La loi de probabilité d'une variable aléatoire décrit la manière dont les probabilités sont réparties sur ses valeurs possibles.

- **Cas discret** : la loi est donnée par une fonction de probabilité.

$$p(x) = \mathbb{P}(X = x). \quad (1.26)$$

- **Cas continu** : la loi est décrite par une densité $f(x)$, telle que

$$\mathbb{P}(a \leq X \leq b) = \int_a^b f(x) dx. \quad (1.27)$$

Fonction de répartition univariée

Elle est également appelée fonction de distribution cumulative. Elle caractérise la loi de probabilité de la variable aléatoire qu'elle soit discrète ou continue. La fonction de répartition

d'une variable aléatoire X est la fonction F_X qui à tout réel x associe la probabilité que X prenne une valeur inférieure ou égale à x :

$$F_X(x) = \mathbb{P}(X \leq x) \quad (1.28)$$

Elle décrit donc la manière dont les probabilités se cumulent le long de l'axe des valeurs possibles de X .

Vecteur aléatoire et loi jointe

Un **vecteur aléatoire** $(X_1, X_2, \dots, X_n)$ est un ensemble de plusieurs variables aléatoires définies sur le même espace de probabilités.

La **loi de probabilité conjointe** décrit la répartition des probabilités sur toutes les combinaisons possibles de valeurs prises simultanément par ces variables.

— **Cas discret** : elle est donnée par une fonction

$$p(x_1, \dots, x_n) = \mathbb{P}(X_1 = x_1, \dots, X_n = x_n).$$

— **Cas continu** : elle est décrite par une densité $f(x_1, \dots, x_n)$, telle que

$$\mathbb{P}(a_1 \leq X_1 \leq b_1, \dots, a_n \leq X_n \leq b_n) = \int_{a_1}^{b_1} \cdots \int_{a_n}^{b_n} f(x_1, \dots, x_n) dx_1 \dots dx_n.$$

Fonction de répartition multivariée

Pour un vecteur aléatoire $(X_1, X_2, \dots, X_n)$ la fonction de répartition multivariée F est définie par :

$$F(x_1, x_2, \dots, x_n) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n) \quad (1.29)$$

Elle donne la probabilité que toutes les composantes soient simultanément inférieures ou égales à des valeurs données, décrivant ainsi la dépendance et la répartition conjointe des variables.

Loi marginale

La loi marginale d'une variable aléatoire correspond à la loi de probabilité obtenue en ne considérant qu'une partie des composantes d'un vecteur aléatoire, en « ignorant » les autres.

Copule

Une copule $\mathcal{C}$ de dimension n représente la fonction de répartition d'un vecteur aléatoire transformé $(U_1 = F_1(X_1), U_2 = F_2(X_2), \dots, U_n = F_n(X_n))$ où les distributions marginales sont uniformes sur $[0, 1]$. C'est à dire, une fonction de répartition de dimension n définie de $[0, 1]^n$ vers $[0, 1]$. Elle peut s'écrire de la forme suivante, $\forall (u_1, \dots, u_n) \in [0, 1]^n$:

$$\mathcal{C}(u_1, \dots, u_n) = \mathbb{P}(U_1 \leq u_1, U_2 \leq u_2, \dots, U_n \leq u_n), \text{ avec } U_1, U_2, \dots, U_n \sim \mathcal{U}([0, 1]) \quad (1.30)$$

Théorème de Sklar

(SKLAR, 1959) introduit la théorie qui porte son nom, le **théorème de Sklar** qui stipule que pour toute fonction de distribution cumulative multivariée $F(x_1, x_2, \dots, x_N)$ ayant des marges données $(F_1(x_1), F_2(x_2), \dots, F_N(x_N))$, il existe une copule $\mathcal{C}$ telle que, pour tout vecteur $(x_1, x_2, \dots, x_N)$, la distribution conjointe puisse s'écrire comme suit :

$$F(x_1, x_2, \dots, x_N) = \mathcal{C}(F_1(x_1), F_2(x_2), \dots, F_N(x_N)) \quad (1.31)$$

Inversement, si $\mathcal{C}$ est une copule et si $F_1, F_2, \dots, F_N$ sont des fonctions de répartitions marginales, alors $F(x_1, x_2, \dots, x_N) = \mathcal{C}(F_1(x_1), F_2(x_2), \dots, F_N(x_N))$ est une fonction de répartition de dimensions N .

Si les lois marginales $(F_1(x_1), F_2(x_2), \dots, F_N(x_N))$ sont toutes continues alors $\mathcal{C}$ est unique. Elle est donnée par la relation :

$$\mathcal{C}(u_1, \dots, u_d) = \Pr[X_1 \leq F_1^{-1}(u_1), \dots, X_d \leq F_d^{-1}(u_d)] \quad (1.32)$$

$$= F(F_1^{-1}(u_1), \dots, F_d^{-1}(u_d)) \quad (1.33)$$

$$= \Pr[F_1(X_1) \leq u_1, \dots, F_d(X_d) \leq u_d] \quad (1.34)$$

Les copules décomposent la probabilité multivariée de répartition à partir de ses marges. Les marges $F_1, F_2, \dots, F_N$ peuvent être n'importe quelle distribution de notre choix, tandis que la copule décrit simplement la relation monotone entre les marges. Ceci est l'un des plus grands avantages des copules car elles divisent le problème de la recherche de la distribution correcte en deux parties : la première consiste à trouver la distribution des marges, et la seconde, leur dépendance.

Cette décomposition rend la modélisation de la dépendance multivariée beaucoup plus aisée, puisqu'elle permet d'estimer séparément les lois marginales et la structure de dépendance.

Méthode d'estimation de la copule

Les copules, introduites par le théorème de (SKLAR, 1959), offrent un cadre théorique permettant de séparer la modélisation des distributions marginales de celle de la structure de dépendance. Cette flexibilité rend possible la représentation de relations non linéaires et de dépendances extrêmes, souvent observées lors de crises financières.

Les méthodes d'estimation des copules se divisent généralement en trois grandes classes : l'approche paramétrique, l'approche semi-paramétrique et l'approche non-paramétrique.

1. Approche paramétrique

On impose à la fois une forme fonctionnelle spécifique pour la copule et pour les distributions marginales. Cette approche est souvent maîtrisée et bien documentée, mais elle présente des inconvénients non négligeables :

- elle nécessite des calculs intensifs (estimation des paramètres, vraisemblance, etc.);
- elle peut générer des problèmes d'optimisation difficiles (convergence, identifiabilité, multi-modalité);
- elle dépend fortement des hypothèses sur les marges : en cas de mauvaise spécification des distributions marginales, l'estimation de la copule peut être biaisée.

2. Approche semi-paramétrique

Dans cette alternative, on conserve une forme paramétrique pour la copule mais on

assouplit les marges en les estimant de manière non paramétrique (ou en recourant à des formes moins strictes). Cette combinaison permet d'augmenter la flexibilité tout en gardant une certaine « structure » pour le lien de dépendance. Elle présente donc un compromis intéressant entre rigidité et liberté.

3. Approche non-paramétrique

Ici, on adopte des modèles totalement non paramétriques pour la copule et/ou les marges. L'idée est de se libérer au maximum des hypothèses structurelles sur les distributions, ce qui offre une grande flexibilité pour capturer des dépendances complexes, asymétriques ou à queues lourdes. En revanche, cette liberté a un coût : elle nécessite souvent un volume de données important et une puissance de calcul élevée.

Dans le contexte de la gestion de portefeuille, l'utilisation des copules permet de générer des scénarios de rendements cohérents avec la réalité empirique, améliorant ainsi l'évaluation du risque extrême et la pertinence des mesures de risque telles que la *CVaR* dans un cadre multi-actifs.

Avant d'appliquer une copule, il est toutefois nécessaire de transformer les séries de rendements en séries *i.i.d.* (indépendantes et identiquement distribuées), car les copules capturent uniquement la *structure de dépendance* entre les variables, indépendamment de leurs distributions marginales.

Les séries financières brutes présentent généralement :

- une dépendance temporelle (autocorrélation des rendements),
- une hétéroscédasticité conditionnelle (volatilité variable dans le temps),
- des queues épaisses et une asymétrie dans les distributions.

Pour corriger ces phénomènes, deux étapes principales sont nécessaires :

1. Modélisation de la moyenne conditionnelle

Un modèle $\text{ARMA}(p, q)$ est ajusté sur les rendements afin de capturer d'éventuelles dépendances linéaires et effets d'autocorrélation (les rendements passés influençant les rendements futurs). Ce modèle est expliqué dans la section [A.2.1](#). Les résidus de ce modèle doivent être exempts de corrélation sérielle pour que le modèle soit correctement spécifié.

2. Modélisation de la variance conditionnelle

Les résidus du modèle ARMA sont ensuite utilisés pour estimer un modèle GARCH ou l'une de ses variantes. L'objectif est d'obtenir des *innovations standardisées* définies par :

$$z_t = \frac{\hat{\varepsilon}_t}{\hat{\sigma}_t}, \quad (1.35)$$

qui sont supposées être *i.i.d.* et prêtes à être utilisées dans l'analyse de dépendance par copules.

Stock-Picking

Le stock picking est une forme de gestion active qui consiste à sélectionner individuellement des actions afin de bâtir un portefeuille capable de surperformer un indice de référence. Contrairement à la gestion passive, qui se limite à répliquer un indice via des véhicules tels que les ETF ou les OPCVM indiciels, le stock picking repose sur une analyse ciblée des entreprises, dans l'idée que certaines d'entre elles présentent un potentiel supérieur au marché global. Cette démarche suppose d'identifier, à l'aide d'outils fondamentaux ou quantitatifs, les

titres les plus prometteurs, puis de les intégrer dans le portefeuille en tenant compte du risque global.

La mise en œuvre d'une stratégie de stock picking repose sur l'analyse de plusieurs critères. On peut les regrouper en 3 grands blocs : fondamental, technique, et marché/sentiment.

Analyse fondamentale

L'analyse fondamentale a pour objectif d'estimer la valeur intrinsèque d'une entreprise en confrontant ses fondamentaux financiers et stratégiques au prix de marché. Elle repose sur une étude approfondie des états financiers, des indicateurs de performance et du positionnement concurrentiel de la société. L'examen des états financiers permet d'évaluer la structure patrimoniale (actifs, dettes, fonds propres), la capacité de création de valeur (croissance du chiffre d'affaires, rentabilité, marges) ainsi que la qualité des flux de trésorerie. L'analyse des indicateurs de performance mobilise les principaux ratios financiers : de valorisation (PER, PBR, PSR, PEG), de rentabilité (ROE, ROA, marges) et de solidité (Debt/Equity, couverture des intérêts, liquidité). Enfin, l'étude du positionnement concurrentiel vise à identifier les avantages compétitifs durables (technologie, coûts, innovation, marque), les barrières à l'entrée et la dynamique de part de marché. La synthèse de ces dimensions permet d'apprécier la solidité financière et stratégique de l'entreprise et de juger si le titre est correctement valorisé par le marché.

Analyse technique

L'analyse technique vise à optimiser le moment d'achat ou de vente d'un titre en étudiant l'évolution passée des prix et des volumes. Contrairement à l'analyse fondamentale, qui cherche à estimer une valeur intrinsèque, elle s'appuie sur l'idée que les marchés traduisent l'ensemble des anticipations et que les comportements tendent à se répéter. L'étude des tendances à travers les moyennes mobiles et l'identification de zones de support et de résistance permettent de situer l'action dans son cycle de marché. Les indicateurs de momentum, tels que le RSI ou le MACD, complètent cette approche en mesurant la vigueur des mouvements et en signalant les phases de surachat ou de survente. L'examen des volumes échangés et de la volatilité apporte une information sur la liquidité du titre et la crédibilité d'une tendance. Enfin, la reconnaissance de configurations graphiques comme les figures en tête-épaules ou en double creux fournit des indices supplémentaires sur la probabilité de poursuite ou d'inversion d'une dynamique. L'intégration de ces éléments permet d'affiner la décision d'investissement en articulant valorisation fondamentale et dynamique de marché.

Analyse du marché et du contexte

L'évaluation d'un titre ne peut se limiter à l'étude de l'entreprise elle-même, car même une société solide peut voir son cours chuter si l'environnement global lui est défavorable. L'analyse du marché et du contexte vise ainsi à intégrer les facteurs exogènes et la psychologie collective des investisseurs. Sur le plan macroéconomique, les cycles de croissance, les variations de taux d'intérêt ou encore l'inflation influencent directement la valorisation des actifs financiers et la capacité bénéficiaire des entreprises. À l'échelle sectorielle, il est essentiel d'examiner la position de l'industrie dans son cycle propre (par exemple l'énergie, la technologie ou la finance) ainsi que les tendances structurelles comme la transition énergétique ou la digitalisation. L'actualité joue également un rôle déterminant : publications de résultats, opérations de fusion-acquisition, évolutions réglementaires ou tensions géopolitiques peuvent

modifier brutalement les anticipations. Enfin, le sentiment de marché, mesuré à travers les flux de capitaux institutionnels et le comportement des investisseurs particuliers, reflète la psychologie collective et conditionne la dynamique des prix. Cette dimension permet de compléter l'analyse fondamentale et technique en apportant une compréhension globale du cadre dans lequel évolue le titre.

1.3 Revue de Litterature

La plupart des travaux récents sur l'IA en finance se concentrent sur l'optimisation de portefeuilles, en comparant différentes méthodes (Markowitz, modèles stochastiques, deep learning) appliquées à des portefeuilles prédéfinis, puis évaluées via des indicateurs classiques (rendement, volatilité, Sharpe). En revanche, peu d'études considèrent la gestion de portefeuille dans son ensemble, incluant la sélection d'actifs. L'étude de (RICHARD, 2021) se distingue en intégrant cette dimension dès la construction du portefeuille. De nombreux travaux récents exploitent le ML pour prédire les rendements futurs ou la volatilité, et alimenter les modèles classiques d'allocation. Parmi ces études, on peut citer : (ALZAMAN, 2024) qui combine l'apprentissage profond, via des modèles Deep RankNet, LSTM optimisés par algorithme génétique développé par (HOLLAND, 1992), pour la sélection de portefeuilles d'actions, démontrant une amélioration significative des performances par rapport aux approches d'optimisation classiques, notamment en période de forte volatilité. (DU, 2022) propose un modèle moyenne-variance fondé sur des portefeuilles stationnaires d'actions cointégrées, dont les rendements sont prédits par des modèles d'apprentissage automatique, montrant que l'utilisation d'un LSTM basé sur l'attention améliore nettement la précision des prévisions et la rentabilité par rapport aux approches classiques. De nombreuses recherches se sont intéressées à l'évaluation comparative des méthodes traditionnelles de modélisation et des approches issues de l'apprentissage automatique. (OLANREWaju, SIKIRU et FAWEHINMI, 2025) développe une stratégie de portefeuille fondée sur des réseaux LSTM et des modèles Transformer pour prédire les rendements d'actifs et alimenter une allocation dynamique via un cadre moyenne-variance, montrant que ces approches deep learning surpassent les méthodes traditionnelles en termes de précision prédictive, de rendements annuels, de ratio de Sharpe et de réduction du drawdown, sur des données multi-actifs mondiales. (RICHARD, 2021) met en place un processus de stockpicking (sélection des actifs) automatisé fondé sur des algorithmes d'IA, qu'il compare à une méthode plus traditionnelle reposant sur des critères fondamentaux (tels que le ratio P/E ou la performance sectorielle). Les portefeuilles ainsi constitués sont ensuite soumis à deux techniques distinctes d'optimisation : d'une part, la théorie moderne du portefeuille de Markowitz, et d'autre part un modèle de deep learning (DeepDow) permettant d'exploiter la structure non linéaire et multidimensionnelle des données financières. L'analyse comparative révèle les différences en termes de rendement, de risque et d'indicateurs de performance (Sharpe, alpha, bêta), soulignant le potentiel de l'IA pour améliorer la robustesse et l'efficacité de la gestion de portefeuille tout en mettant en évidence les limites pratiques liées à la mise en œuvre.

Plus récemment, le reinforcement learning a émergé comme un cadre puissant pour aborder l'optimisation séquentielle de portefeuille, donnant lieu à plusieurs études notables. Parmi celles-ci, (OLANREWaju et al., 2025) examinent l'efficacité de modèles d'apprentissage automatique, reinforcement learning (RL) sans modèle, réseau de neurones profond (DNN) et Random Forest pour l'allocation dynamique d'actifs dans un portefeuille multiproduits U.S comparés aux approches Markowitz et Black-Litterman. Les variables utilisées incluent les

rendements glissants (1, 3 et 6 mois), la volatilité réalisée, l'indice macroéconomique VIX qui est un indicateur de volatilité du marché financier américain. Une validation sur des événements récents et extrêmes (COVID-19, régime inflationniste 2022) montrant que le RL apprend des politiques d'allocation capables d'anticiper les pics de volatilité et de réduire significativement le drawdown, ce qui renforce la preuve de robustesse en conditions réelles. (JIANG, OLMO et ATWI, 2024) développent un cadre de deep reinforcement learning sans modèle, basé sur l'algorithme Twin-Delayed Deep Deterministic Policy Gradient (TD3), pour optimiser l'allocation de portefeuilles dans des marchés financiers dynamiques, complexes et de grande dimension. L'approche intègre l'aversion au risque et les coûts de transaction au sein d'une fonction de récompense moyenne-variance étendue inspirée de Markowitz, et exploite des réseaux neuronaux pour extraire automatiquement des représentations pertinentes à partir de données de haute dimension. Testée sur les constituants du Dow Jones Industrial Average et du S&P 100, la méthode proposée surpasse significativement les stratégies classiques (minimum variance, maximum Sharpe) ainsi que d'autres approches DRL (PPO, DDPG) en termes de rendement ajusté au risque. Les résultats empiriques confirment la robustesse du modèle face aux variations des paramètres d'aversion au risque et de coûts de transaction, et sa capacité à gérer efficacement des portefeuilles de grande taille. (JANG et SEONG, 2023) proposent une approche novatrice combinant la théorie moderne du portefeuille avec le deep reinforcement learning (DRL). Pour traiter le caractère multimodal des données, ils utilisent une décomposition de Tucker intégrant des indicateurs techniques et des covariables de rendement.

(HACHAÏCHI et LANWER, 2024) ont comparé plusieurs algorithmes de Deep Reinforcement Learning (DDPG, PPO, A2C, SAC, TD3) pour l'optimisation de portefeuilles sur les indices CAC40, DJIA30 et DAX30, montrant que ces méthodes surpassent les approches classiques comme la moyenne-variance et les indices de marché en termes de rendement ajusté au risque.

La littérature sur l'application du reinforcement learning à l'optimisation de portefeuille est abondante, et mobilise une variété d'algorithmes tels que le Q-learning, ainsi que des approches plus récentes comme le Deep Q-Network (DQN), le Double DQN (DDQN), PPO. De nombreux travaux illustrent cette diversité, parmi lesquels ceux de (MOODY et SAFFELL, 1998), (DU, ZHAI et LV, 2016), (PENDHARKAR et CUSATIS, 2018) utilisant le Q-learning, (PENDHARKAR et CUSATIS, 2018) appliquant le SARSA ou encore (PARK, SIM et CHOI, 2019), (GAO et al., 2020) qui utilisent l'algorithme DQN.

Plusieurs travaux récents combinent l'apprentissage par renforcement avec l'analyse de sentiment issue de données textuelles, notamment les actualités financières. Par exemple (CORIAT et BENHAMOU, 2025) proposent un cadre hiérarchique de gestion de portefeuille intégrant des modèles de langage légers spécialisés (FinBERT) avec le Deep Reinforcement Learning. Leur architecture à trois niveaux met en œuvre : (i) des agents de base traitant séparément les indicateurs de marché et les scores de sentiment, (ii) des méta-agents agrégeant ces décisions par modalité, et (iii) un super-agent fusionnant les signaux quantitatifs et qualitatifs pour l'allocation finale. Testé sur des données 2018–2024 après un entraînement sur 2003–2017, le super-agent atteint un rendement annualisé de 26 % et un ratio de Sharpe de 1,2 surpassant largement l'indice S&P500 (13,2 %, Sharpe = 0,63) et un portefeuille équipondéré (7,5 %, Sharpe = 0,57), ainsi que plusieurs approches RL de l'état de l'art. Les auteurs démontrent que l'intégration des signaux de sentiment améliore systématiquement les

performances par rapport aux agents purement quantitatifs. Toutefois, les résultats supposent des données disponibles de manière synchrone et ne tiennent pas compte des coûts de transaction, ce qui peut conduire à une surestimation de la performance réelle.

Parallèlement à ces travaux mobilisant l'intelligence artificielle, plusieurs recherches récentes s'appuient sur les copules pour modéliser la dépendance multivariée et améliorer l'évaluation du risque de portefeuille. (PAREEK et GHOSH, 2025) proposent un modèle semi-paramétrique dynamique associant marges paramétriques, modélisées par la distribution Skewed Generalized t (SGT), et copules non paramétriques estimées via l'Empirical Beta Copula (EBC) introduit par (SEGERS, SIBUYA et TSUKAHARA, 2016). Plus flexible que les copules paramétriques aux formes fixes, l'EBC capture des structures de dépendance complexes et asymétriques, particulièrement adaptées aux rendements non gaussiens, et son application sur fenêtres glissantes permet de suivre les corrélations en fonction des régimes de marché. La SGT, capable de représenter asymétrie et queues épaisses, englobe de nombreuses distributions connues (Laplace, normale, T de Student, Cauchy, etc.). L'optimisation, de type Global Minimum Variance avec contraintes réalistes (investissement complet, positions longues, rendement minimal supérieur à l'équipondéré) appliquée sur les marchés américain, indien et hongkongais, montre une meilleure résilience et des performances supérieures en régimes volatils, grâce à l'adaptation dynamique aux changements structurels de dépendance et de risque par rapport aux modèles d'optimisation moyenne-variance sous hypothèse de normalité multivariée avec matrice de covariance d'échantillon, de portefeuille naïf équipondéré et à celui utilisant la même approche copule mais sans contrainte de rendement minimal. Pour chaque marché étudié (États-Unis, Inde, Hong Kong), ils retiennent des portefeuilles de 20 sociétés sélectionnées à partir du S&P 500 (États-Unis), du NIFTY 50 (Inde) et des actions les plus échangées à la HKEX (Hong Kong). Pour eux, ce choix vise à assurer une diversification suffisante tout en maintenant une taille d'échantillon qui facilite la visualisation des résultats et l'interprétation des inférences, tout en réduisant la complexité computationnelle. Les titres sont choisis selon des critères de forte capitalisation boursière et d'influence économique significative, garantissant ainsi la représentativité sectorielle et la pertinence empirique des allocations obtenues. (CHATSANGA et PARKES, 2017) développent un modèle d'optimisation stochastique international en deux étapes intégrant simultanément l'allocation d'actifs et la couverture de change. La génération des scénarios repose sur des Regular Vine Copulas (RVC) qui permettent de modéliser la dépendance asymétrique et la non-normalité des rendements, surmontant ainsi les limites des approches basées sur la corrélation linéaire et l'hypothèse de normalité. Ils estiment les fonctions de densité de probabilité de chaque série de rendements par KDE (une technique statistique non paramétrique utilisée pour estimer la fonction de densité de probabilité d'une variable aléatoire) avec le noyau d'Epanechnikov et une largeur de bande choisie selon la règle de (SILVERMAN, 1986) puis calcule ensuite la fonction de répartition (CDF) pour transformer en valeurs uniformes $[0, 1]$, nécessaires pour l'étape copule. Le risque est mesuré par le Conditional Value-at-Risk (CVaR), garantissant la prise en compte des pertes extrêmes. Le modèle inclut les coûts de transaction et de couverture via contrats à terme de change, ainsi que des contraintes de cardinalité et de gestion de l'exposition devise. Les résultats empiriques montrent que les portefeuilles multiproduits optimisés avec scénarios RVC offrent de meilleures performances ajustées au risque que ceux issus d'hypothèses gaussiennes classiques, en particulier pour des niveaux de rendement cibles élevés. (SEMENOV et SMAGULOV, 2017) étudient l'utilisation des copules pour représenter la dépendance multivariée entre séries financières et évaluer le risque de portefeuille. Les auteurs appliquent des copules gaussienne, Student's t et vine régulière (R-vine) à un portefeuille de contrats à terme sur quatre actifs russes, en utilisant une modélisation des marginales non

normales (Hyperbolique, Stable, Meixner). L'optimisation repose sur le cadre mean-CVaR, formulé comme un problème de programmation linéaire. Les résultats montrent que les courbes de VaR et CVaR simulées via les copules sont systématiquement inférieures aux estimations empiriques, traduisant une meilleure capacité prédictive, la copule R-vine offrant la performance la plus robuste. Cette étude souligne l'importance du choix de la structure de dépendance dans la modélisation des risques et l'optimisation de portefeuille. En dehors des

copules, de nombreuses approches sont mobilisées pour modéliser la dépendance multivariée, telles que l'analyse en composantes principales, les réseaux bayésiens, les techniques floues, l'analyse factorielle. (FOKOU, 2006) étudie la mesure du risque de marché à travers la Value-at-Risk (VaR) et la Conditional Value-at-Risk (CVaR) en appliquant une approche originale combinant l'Independent Component Analysis (ICA), issue du traitement du signal, et la modélisation par mélanges gaussiens afin de prendre en compte à la fois la dépendance entre actifs et la présence de queues de distribution épaisses. L'analyse porte sur un portefeuille composé des indices BEL20, CAC40 et DAX30, avec des horizons de 1, 5 et 10 jours. Les résultats empiriques montrent que cette méthodologie fournit des estimations de VaR et CVaR plus robustes, avec des taux d'échec inférieurs à ceux observés avec les approches historique et variance-covariance, ce qui souligne son efficacité pour la modélisation du risque extrême. Dans la continuité de ces travaux, plusieurs recherches se sont attachées à renforcer

la robustesse des mesures de risque, en particulier à travers des extensions de la CVaR. (ZHU et FUKUSHIMA, 2009) étendent l'approche CVar en introduisant la mesure de risque WCVaR, une version robuste intégrant différentes structures d'incertitude de distribution (mixture, box, ellipsoïdale) et appliquée à l'optimisation de portefeuille via des formulations linéaires ou coniques, afin de mieux maîtriser le risque extrême en contexte incertain. Dans la même lignée, certaines recherches combinent le WCVaR avec des modèles de dépendance basés sur les copules, comme dans l'étude de (KAKOURIS et RUSTEM, 2014) qui exploitent des copules multivariées pour modéliser les corrélations asymétriques entre actifs, puis appliquent le WCVaR afin d'optimiser la composition du portefeuille tout en contrôlant le risque extrême dans un cadre robuste. Plus récemment, (HAN et LI, 2020) proposent une approche robuste combinant le WCVaR et les Regular Vine Copulas afin de modéliser finement la dépendance non linéaire et asymétrique entre actifs, ce qui permet d'optimiser des portefeuilles plus résilients face aux chocs extrêmes et aux incertitudes de distribution. Dans cette continuité, (ALOTAIBI, DALLA VALLE et CRAVEN, 2022) développent une approche innovante combinant le WCVaR avec des modèles GARCH-Copula, permettant à la fois de capturer la volatilité conditionnelle des rendements et la dépendance non linéaire entre actifs.

1.4 Conclusion

La revue de littérature met en évidence une évolution progressive des modèles de gestion de portefeuille, allant des approches classiques vers des mesures de risque robustes, des modèles de dépendance avancés et enfin des méthodes computationnelles basées sur le ML, le DL et le RL. Ces avancées visent toutes à mieux capturer la complexité et l'incertitude des marchés financiers. Toutefois, aucune étude n'a, à notre connaissance, intégré simultanément ces trois dimensions robustesse du risque, dépendance multivariée avancée et intelligence artificielle dans un cadre unifié. De plus, la plupart des travaux recensés portent sur des marchés développés ou émergents non africains, alors que peu d'études exploitent les spécificités

des marchés africains, notamment celui de la BRVM. Ce double constat souligne un vide scientifique et motive l'exploration d'approches hybrides appliquées au contexte africain, afin de proposer une gestion de portefeuille à la fois plus robuste, réaliste et adaptée.

CHAPITRE

2

CADRE MÉTHODOLOGIQUE DE L'ÉTUDE

Contenu

2.1	Introduction	28
2.2	Outils et données utilisés	28
2.2.1	Outils utilisés	28
2.2.2	Données utilisées	28
2.3	Méthodes	29
2.3.1	Copule	29
2.3.2	Sélection des titres pour la constitution du portefeuille	31
2.3.3	Apprentissage par renforcement	34
2.3.4	Modèles de référence (benchmarks)	38
2.3.5	Protocole d'entraînement, validation et test	39
2.4	Conclusion	40

2.1 Introduction

Ce chapitre décrit les fondations méthodologiques de l'étude, en détaillant les outils, données et techniques mobilisés pour l'analyse et la gestion dynamique de portefeuille. Il expose comment les données financières de la BRVM sont collectées, préparées et transformées pour être exploitées dans des modèles statistiques et d'apprentissage par renforcement. L'objectif est de présenter un cadre rigoureux et structuré, permettant de modéliser la dépendance entre actifs, de sélectionner les titres pertinents et de développer des stratégies de portefeuille optimales.

2.2 Outils et données utilisés

2.2.1 Outils utilisés

- **Python** a été mobilisé pour le [traitement des données](#) et le [développement du modèle](#). Grâce à ses bibliothèques spécialisées (NumPy, Pandas, PyTorch, Tensorflow etc.), il a permis le nettoyage, la transformation et l'analyse des séries financières, ainsi que l'implémentation et l'entraînement de l'agent d'apprentissage par renforcement.
- **R** Le package **BRVM**, disponible sur GitHub (<https://github.com/Koffi-Fredysessie/BRVM>), constitue un outil essentiel pour la collecte des données de la [BRVM](#), bourse régionale regroupant plusieurs pays d'Afrique de l'Ouest. Ce package offre une interface conviviale permettant d'accéder à l'historique des cours, aux volumes d'échange ainsi qu'à divers indicateurs financiers des actions cotées. Il simplifie ainsi l'extraction et l'analyse des informations pertinentes, rendant possible une meilleure compréhension du fonctionnement des marchés financiers ouest-africains.
- **Visual Studio Code (VS Code)** a servi d'[environnement de développement intégré \(IDE\)](#). Il a permis d'écrire et de tester le code en Python et en R, tout en offrant un support pratique pour la rédaction du mémoire grâce à son extension [LaTeX Workshop](#). Cet outil polyvalent a facilité à la fois le développement technique et la production scientifique.

2.2.2 Données utilisées

Cette section décrit les données utilisées dans le cadre de l'étude, en précisant leur origine, leur nature et leur période de couverture. Ces informations sont essentielles pour garantir la fiabilité des analyses et la pertinence des résultats obtenus.

Toutes les données exploitées dans le cadre de cette recherche ont été téléchargées à l'aide du package **BRVM** sous [R](#), qui offre un accès direct et centralisé aux informations de la Bourse Régionale des Valeurs Mobilières (BRVM). Ces données proviennent pour la plupart du site officiel [RichBourse](#). Elles se déclinent en plusieurs ensembles principaux :

1. **Ensemble de métadonnées sur les actions cotées**

Cet ensemble regroupe le nom complet des actions, leur secteur d'activité ainsi que leur pays d'origine. Ces informations sont obtenues via la fonction `BRVM_ticker_desc()`, qui renvoie une description détaillée des tickers de la BRVM.

2. **Ensemble de données boursières quotidiennes**

Il contient les prix de clôture ajustés ainsi que les volumes ajustés quotidiens de

toutes les sociétés cotées. Chaque entreprise est collectée individuellement à l'aide de la fonction `BRVM_get(".symbol", ".from", ".to")`, puis consolidée pour constituer une base unique de séries temporelles.

Les données couvrent, pour chaque action, la période allant de sa date d'introduction en bourse jusqu'au mois d'août 2025.

3. Ensemble de données sur les dividendes

Ce jeu de données renseigne sur les dividendes annuels distribués par chaque entreprise depuis leur création jusqu'en 2024, permettant ainsi d'intégrer une dimension de rendement aux analyses.

4. Ensemble de données sur le capital social

Il regroupe le nombre total d'actions en circulation pour chaque société, obtenu grâce à la fonction `BRVM_company_cap()`. Ces informations sont essentielles pour l'évaluation de la capitalisation boursière des entreprises.

2.3 Méthodes

2.3.1 Copule

Méthodes d'estimation de la copule

Dans notre étude, nous retenons l'approche semi-paramétrique.

Ce choix se justifie par plusieurs raisons techniques et opérationnelles :

- **Robustesse vis-à-vis des marges** : en estimant les distributions marginales de manière non paramétrique, on évite d'imposer des hypothèses restrictives sur leur forme. Cela permet de capturer les asymétries, queues épaisses et autres propriétés observées dans les rendements financiers.
- **Efficience de dépendance** : la copule paramétrique permet une estimation stable de la structure de dépendance, notamment en queue, avec des paramètres interprétables.
- **Compromis biais-variance** : cette approche limite le risque de mauvaise spécification des marges et la variance élevée des modèles entièrement non paramétriques, tout en restant calculatoirement raisonnable.
- **Scalabilité et adaptabilité** : elle s'applique efficacement aux données multivariées et peut être étendue à des constructions vine copulas pour des portefeuilles nombreux.

En résumé, le semi-paramétrique offre un compromis optimal entre robustesse, précision et interprétabilité, ce qui en fait la méthode la plus adaptée pour la modélisation multivariée des rendements financiers.

Modélisation des marges

Pour modéliser les distributions marginales, nous utilisons un [estimateur de densité par noyau \(KDE\)](#) encore appelé [méthode de Parzen-Rosenblatt](#), méthode non-paramétrique qui permet d'estimer la densité d'une variable sans faire d'hypothèses sur sa loi.

Estimation par noyau (KDE) Soit un échantillon de n observations $x_1, x_2, \dots, x_n$. L'estimation par noyau de la densité au point x est donnée par :

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right) \quad (2.1)$$

où :

- K est le **noyau (kernel)**
- h est la **fenêtre**, paramètre critique qui régule le degré de lissage.

Cette approche offre une plus grande flexibilité et s'adapte mieux aux données réelles que les lois classiques, qui ont montré leurs limites lors des tests préliminaires. Le choix du paramètre de lissage est crucial pour obtenir une estimation précise, équilibrant biais et variance.

Modélisation de la dépendance

Une fois les marges correctement estimées, la seconde étape consiste à modéliser la structure de dépendance entre les actifs, ce qui constitue le cœur de la copule.

Pour modéliser efficacement la dépendance multivariée, nous utilisons des vines copulas, qui permettent de décomposer une copule complexe en une série de copules bivariées. Ce choix offre plusieurs avantages :

- **Décomposition flexible de la dépendance** : les vines copulas (copule en vigne ou copule en réseau arborescent) décomposent la copule multivariée en une succession de copules bivariées conditionnelles, permettant de modéliser finement les relations entre paires d'actifs.
- **Adaptation locale aux caractéristiques des paires** : chaque copule bivariée peut être choisie indépendamment (t, Clayton, Gumbel, etc.), ce qui améliore la capture des dépendances asymétriques et en queue.
- **Scalabilité et tractabilité** : les copules en vignes restent efficaces même en haute dimension, avec des calculs plus simples et stables

Nous utilisons des R-vine copulas (copules en vigne régulière) plutôt que des C-vines (copules en vigne canonique) ou des D-vines (copules en vigne séquentielle). Ce choix se justifie par le contexte spécifique de la BRVM : bien qu'il existe un indice principal sur la BRVM, celui-ci n'est pas tradable et ne peut donc pas servir de nœud central pour structurer la dépendance.

En effet, les C-vines supposent l'existence d'un nœud central dominant, ce qui n'est pas adapté ici. Les D-vines décomposent la copule multivariée en une succession de copules bivariées conditionnelles, offrant plus de flexibilité que les C-vines mais restant limitées par la structure séquentielle.

Les R-vines, en revanche, combinent la flexibilité des D-vines avec une structure plus générale : elles permettent de modéliser les dépendances complexes et asymétriques entre toutes les paires d'actions et de choisir le type de copule le plus adapté pour chaque paire. Cette approche est particulièrement pertinente pour capturer les relations entre actions sur la BRVM, où les corrélations ne suivent pas un schéma simple ou hiérarchique.

Préparation des données pour la modélisation copule

Avant de commencer la modélisation proprement dite, nous devons préparer les données. Cela inclut plusieurs étapes clés :

- **Transformation en rendements logarithmiques**
Cette transformation permet de stabiliser la variance, de centrer les séries autour d'une moyenne constante, et de faciliter leur modélisation statistique.
Pour examiner la nature stochastique des séries de prix, les tests de stationnarité

d'Augmented Dickey-Fuller (ADF) et de Kwiatkowski-Phillips-Schmidt-Shin (KPSS) ont été appliqués à l'ensemble des titres considérés. Pour davantage de détails sur les tests de stationnarité, le lecteur peut se référer à A.3.1. Les résultats obtenus (voir le tableau A.4) montrent que les séries sont non stationnaires selon les deux tests, ce qui indique que leurs moyennes et variances varient dans le temps.

Afin de pallier cette non-stationnarité, les séries de prix ont été transformées en rendements logarithmiques, qui sont calculés à partir des prix de clôture ajustés selon la formule :

$$r_t = \ln \left(\frac{P_t}{P_{t-1}} \right) \quad (2.2)$$

où P_t et P_{t-1} représentent les prix de clôture aux instants t et $t - 1$. Les rendements ainsi obtenus présentent des propriétés plus proches de la stationnarité, comme le confirment les tests ADF et KPSS réappliqués sur ces nouvelles séries (voir le tableau A.5).

- **Détection et correction des phénomènes d'autocorrélation et d'hétéroscédasticité**
Les rendements financiers présentent souvent des dépendances temporelles (autocorrélation) et une volatilité variable dans le temps (hétéroscédasticité). L'analyse des fonctions ACF et PACF, complétée par les tests de Ljung-Box (A.3.2) et d'Engle (ARCH) (A.3.3), a confirmé la présence de ces effets. Afin de les corriger et d'obtenir des résidus indépendants et identiquement distribués (i.i.d.), nécessaires à la modélisation copule, nous avons ajusté des modèles ARMA-GJR-GARCH. Pour en savoir plus sur ces modèles, le lecteur peut se référer aux sections A.2.1 et A.2.2 de A.2.

Après ajustement des modèles ARMA-GJR-GARCH, les résidus standardisés sont obtenus. Ces résidus, qui sont supposés être i.i.d., constituent les données d'entrée pour la modélisation des marges et de la copule.

Pour plus de détails sur la modélisation des R-vine copulas, le lecteur peut se référer aux travaux de MANJUNATHA et al., 2024 ainsi qu'à la thèse de SOMMER, 2022.

2.3.2 Sélection des titres pour la constitution du portefeuille

Dans le cadre de ce travail, le *stock picking* est mobilisé comme une étape intermédiaire entre l'univers d'investissement et l'optimisation de portefeuille. Contrairement à une sélection discrétionnaire réalisée par le gestionnaire du portefeuille ou l'investisseur, il s'agit d'une démarche méthodologique reposant sur un processus algorithmique de sélection multi-critères.

Ce processus vise à identifier les actifs les plus intéressants de la bourse, offrant :

- un **bon rendement** (mesuré ici par le rendement simple),
- une **faible volatilité**,
- une **liquidité suffisante**,
- et un **rendement de dividende attractif**.

Il s'agit donc d'une démarche méthodique permettant de constituer un portefeuille représentatif et diversifié, tout en sélectionnant les titres offrant le meilleur compromis entre performance et risque.

1. Définition de la fenêtre d'observation

Pour chaque actif i à la date de rééquilibrage t , on considère une fenêtre glissante de W semaines :

$$\mathcal{W}_{i,t} = \{P_{i,t-W}, \dots, P_{i,t-1}\}, \quad (2.3)$$

où $P_{i,s}$ désigne le prix de clôture de l'actif i à la date s .

2. Construction du masque de disponibilité

Certains actifs peuvent manquer de données sur la fenêtre d'observation. On définit un *masque binaire* :

$$\text{mask}_{i,t} = \begin{cases} 1, & \text{si les données de } i \text{ sont disponibles sur } \mathcal{W}_{i,t} \\ 0, & \text{sinon} \end{cases} \quad (2.4)$$

Ce masque garantit que seules les actions avec des données complètes sont considérées pour le calcul des indicateurs et le score final.

3. Calcul des indicateurs (features)

Pour les actifs valides ($\text{mask} = 1$), on calcule les indicateurs suivants :

Momentum (performance cumulée sur la fenêtre) :

$$\mu_{i,t} = \frac{P_{i,t-1}}{P_{i,t-W}} - 1 \quad (2.5)$$

Volatilité (écart-type des rendements simples) :

$$\sigma_{i,t} = \text{std} \left(R_{i,s}, s \in \mathcal{W}_{i,t} \right), \quad R_{i,s} = \frac{P_{i,s} - P_{i,s-1}}{P_{i,s-1}} \quad (2.6)$$

Liquidité (volume moyen échangé) :

$$L_{i,t} = \frac{1}{W} \sum_{s \in \mathcal{W}_{i,t}} V_{i,s} \quad (2.7)$$

où $V_{i,s}$ est le volume échangé à la date s .

Rendement du dividende (*dividend yield*) :

$$D_{i,t} = \frac{\text{Div}_{i,t-1}}{P_{i,t-1}}, \quad (2.8)$$

où $\text{Div}_{i,t-1}$ est le dividende versé par action l'année précédente.

4. Normalisation par rang

Après avoir calculé les différentes features μ pour le momentum, σ pour la volatilité, L pour la liquidité, et D pour le dividend yield, il est nécessaire de les mettre sur une même échelle afin de pouvoir les combiner dans un score global. Les features ont des unités et des ordres de grandeur très différents :

- Le momentum μ est une variation en pourcentage.
- La volatilité σ est un écart-type, généralement en fraction ou en pourcentage.
- La liquidité L correspond à un volume moyen, souvent très grand.
- Le dividend yield D est un ratio généralement faible.

Si on les additionnait directement, certaines features domineraient le score simplement en raison de leur amplitude. La **normalisation par rang** permet de résoudre ce problème en transformant chaque feature en un rang relatif compris entre 0 et 1, de manière non paramétrique, indépendante des unités et robuste aux valeurs extrêmes (*outliers*).

Concrètement, pour chaque feature $X_{i,t}^{(j)}$ à la date t :

- (a) On classe tous les actifs valides ($\text{mask} = 1$) selon la valeur de cette feature, du plus faible au plus élevé.

- (b) On attribue à chaque actif i un rang r_i dans cette liste (1 pour le plus faible, N_t pour le plus élevé, où N_t est le nombre d'actifs valides à la date t).
- (c) On divise ce rang par N_t pour obtenir une valeur normalisée comprise entre 0 et 1 :

$$R_{i,t}^{(j)} = \frac{\text{rank}(X_{i,t}^{(j)})}{N_t}, \quad X_{i,t}^{(j)} \in \{\mu_{i,t}, \sigma_{i,t}, L_{i,t}, D_{i,t}\}, \quad (2.9)$$

Ainsi, le meilleur actif pour une feature obtient une valeur proche de 1, tandis que le moins performant obtient une valeur proche de 0. Cette approche permet de comparer et combiner facilement les différentes features dans un score global, tout en conservant la hiérarchie relative des actifs pour chaque critère.

5. Score multi-critères

On combine les indicateurs normalisés par rang avec des pondérations ($w_\mu, w_\sigma, w_L, w_D$) pour obtenir un score global pour chaque actif :

$$S_{i,t} = w_\mu R_{i,t}^{(\mu)} - w_\sigma R_{i,t}^{(\sigma)} + w_L R_{i,t}^{(L)} + w_D R_{i,t}^{(D)} \quad (2.10)$$

Dans le cadre de ce travail, nous avons choisi d'attribuer une pondération égale de 0,25 à chacun des quatre critères :

$$w_\mu = w_\sigma = w_L = w_D = 0.25$$

Cette pondération égale a été retenue pour plusieurs raisons :

- Elle permet de traiter chaque critère comme également important dans la sélection des actifs, évitant qu'un indicateur domine le score global simplement en raison de sa magnitude ou de sa volatilité.
- Elle reflète une approche équilibrée, cohérente avec l'objectif d'identifier des actions offrant simultanément de bonnes performances récentes (momentum), une volatilité faible, une liquidité suffisante et un rendement du dividende intéressant.
- En l'absence d'information supplémentaire indiquant qu'un critère devrait être prioritaire, cette pondération uniforme constitue une hypothèse raisonnable pour une première sélection méthodologique.

Ainsi, le score final $S_{i,t}$ permet de classer les actifs de manière synthétique, en tenant compte de plusieurs dimensions pertinentes pour la constitution d'un portefeuille attractif et diversifié.

6. Sélection du portefeuille

Une fois le score multi-critères $S_{i,t}$ calculé pour tous les actifs disponibles, on applique le masque de disponibilité afin de ne conserver que les titres avec des données complètes sur la fenêtre d'observation :

$$\tilde{S}_{i,t} = \begin{cases} S_{i,t}, & \text{si } \text{mask}_{i,t} = 1, \\ 0, & \text{sinon.} \end{cases} \quad (2.11)$$

Les K actifs ayant les scores ajustés les plus élevés sont ensuite retenus pour constituer le portefeuille à la date t :

$$P_t = \text{Top-}K_i \tilde{S}_{i,t} \quad (2.12)$$

Cette démarche garantit que le portefeuille :

- contient uniquement des actifs pour lesquels toutes les données sont disponibles et fiables,
- privilégie les actions offrant simultanément un bon rendement récent, une faible volatilité, une liquidité suffisante et un rendement de dividende attractif,
- repose sur une méthodologie systématique et non discrétionnaire, assurant un compromis optimal entre performance et risque.

Bien que certaines informations fondamentales (ratios financiers, données comptables détaillées, etc.) n'aient pas pu être intégrées en raison de limitations de disponibilité, les dividendes ont été pris en compte dans le processus via le calcul du *dividend yield*. Ainsi, la sélection repose principalement sur des critères techniques, enrichis d'un indicateur fondamental.

Dans ce travail, le nombre d'actifs sélectionnés est fixé à $K = 10$, ce qui permet un équilibre entre diversification, lisibilité et pertinence des résultats. Le portefeuille ainsi constitué peut ensuite être comparé à l'indice BRVM Prestige comme benchmark et aux résultats d'une approche d'optimisation de type Markowitz.

2.3.3 Apprentissage par renforcement

Modèle de RL pour la gestion de portefeuille

Dans ce travail, nous mettons en œuvre l'algorithme **Soft Actor-Critic (SAC)**, une méthode de **Deep Reinforcement Learning** sans modèle (**model-free**). SAC combine les approches **Actor-Critic** avec une régularisation par l'entropie, permettant à l'agent d'apprendre une politique stochastique adaptée aux environnements à espace d'actions continues et aux dynamiques stochastiques. Cette approche assure à la fois **stabilité** et **convergence**, même dans des contextes où les méthodes Actor-Critic classiques peuvent rencontrer des difficultés. Les détails techniques et les fondements mathématiques du modèle Soft Actor-Critic sont présentés dans A.2.3, à laquelle le lecteur est invité à se référer pour une compréhension approfondie. Pour appliquer l'apprentissage par renforcement à la gestion de portefeuille, nous devons définir les éléments clés du modèle RL en fonction du contexte financier. Voici comment nous avons structuré notre modèle :

Environnement

L'environnement modélise la gestion dynamique d'un portefeuille d'actions cotées sur la BRVM (Bourse Régionale des Valeurs Mobilières). Il définit le cadre dans lequel l'agent apprend à allouer des ressources entre les différentes sociétés pour maximiser la performance du portefeuille. L'environnement évolue selon les données historiques de la BRVM. Après chaque action a_t , l'état s_{t+1} est mis à jour en fonction de l'évolution des prix et de la nouvelle répartition du portefeuille.

États

Nous définissons l'état de l'environnement à chaque instant t comme un vecteur d'observations financières, incluant des indicateurs tels que :

1. Poids du portefeuille à l'instant t (**Dimension : N(Nombre d'actifs de la BRVM)**)

- $\mathbf{w}_t = (w_{1,t}, w_{2,t}, \dots, w_{N,t})$, où $w_{i,t}$ est la proportion de l'actif i dans le portefeuille (somme = 1).
- 2. Valeur totale du portefeuille actualisée à l'instant t
- 3. Cash disponible à l'instant t
- 4. Données fondamentales des k actifs sélectionnés
 - Nombre d'actions en circulations
 - Secteur (Transformé en valeur numérique)
 - Pays (Transformé en valeur numérique)
 - Dividende versé
- 5. Valeurs des indicateurs techniques des K actifs sélectionnés Les entrées du modèle sont constituées d'un ensemble d'indicateurs techniques financiers : **MACD**, **RSI**, **CCI**, **STOCH_K**, **WILLR**, bandes de Bollinger (BB_Upper , BB_Middle , BB_Lower), **EMA**, **ATR**, **SAR**, valeurs de clôture retardées ($Close_Lag1$, $Close_Lag3$, $Close_Lag5$), moyennes mobiles (SMA_50 , SMA_20), ainsi que **OBV**, **MFI**, **ADX** et **Volume**. Ces indicateurs visent à capturer différentes dynamiques du marché, telles que la tendance, la volatilité et la pression acheteuse/vendeuse. Pour plus de détails sur la définition et le calcul de ces indicateurs, le lecteur est invité à se référer à [A.4](#).

Actions

Dans ce travail, nous considérons un problème de contrôle de portefeuille où les actions sont **continues**. Chaque action correspond à un vecteur de *poids d'allocation des actifs* :

$$\mathbf{w}_t = (w_{1,t}, w_{2,t}, \dots, w_{k,t}) \in \mathbb{R}^k, \quad (2.13)$$

avec k le nombre d'actifs dans le portefeuille. Les composantes du vecteur satisfont les contraintes :

$$\sum_{i=1}^k w_{i,t} = 1, \quad w_{i,t} \geq 0, \quad \forall i \in \{1, \dots, k\}. \quad (2.14)$$

Cette formulation permet de représenter des décisions d'investissement graduelles et proportionnelles, offrant une granularité supérieure à celle des approches discrètes traditionnelles (acheter, vendre ou rester).

Récompenses

L'agent doit maximiser le rendement net du portefeuille tout en minimisant le risque extrême et les coûts de transaction. C'est la fonction objective transformée en signal pour l'agent.

1. Rendement net du portefeuille

Le rendement total pondéré par les poids actuels des k actifs est :

$$R_t = \sum_{i=1}^k w_i \cdot r_{i,t} \quad (2.15)$$

où :

- w_i : poids de l'actif i dans le portefeuille
- $r_{i,t}$: rendement de l'actif i à la période t

2. Risque extrême (CVaR)

Pour pénaliser les pertes importantes, on calcule la Conditional Value at Risk (CVaR) du portefeuille sur un horizon récent :

$$\text{CVaR}_\alpha = \mathbb{E}[\text{pertes} \mid \text{pertes} \geq q_\alpha] \quad (2.16)$$

Pondéré par le profil utilisateur (aversion au risque λ) :

$$\text{penalité}_{\text{risque}} = \lambda \cdot \text{CVaR}_\alpha \quad (2.17)$$

3. Coûts de transaction

Chaque rééquilibrage génère un coût proportionnel :

$$\text{transaction cost} = \sum_{i=1}^k |w_i^{\text{nouveau}} - w_i^{\text{actuel}}| \cdot c \quad (2.18)$$

où c est le taux de commission (ex. 0.1%).

Formule complète du reward

$$\text{reward}_t = R_t - \lambda \cdot \text{CVaR}_\alpha - \text{transaction cost} \quad (2.19)$$

- R_t : incite à maximiser le rendement
- CVaR_α : incite à éviter les pertes extrêmes
- transaction cost : incite à limiter les transactions inutiles

Temporalité

- Horizon d'épisode : plusieurs années de données historiques de la BRVM,
- Fréquence de décision : quotidienne, hebdomadaire ou mensuelle, selon la granularité choisie pour l'étude,
- Chaque pas de temps correspond à la clôture d'une session de marché (jour, semaine ou mois),
- Cette flexibilité permet d'évaluer l'impact de la fréquence des décisions sur la performance du portefeuille.

Contraintes et règles du portefeuille

- **Long-Only** : Pas de vente à découvert.
- **Pas d'effet de levier** : L'agent ne peut pas emprunter des fonds pour augmenter la taille de son portefeuille au-delà du capital initial.
- **Pas d'ajout de capital** : Le capital initial est fixe et ne peut pas être augmenté par des apports supplémentaires.

- **Pas de retrait de capital** : Aucun retrait de fonds n'est autorisé pendant la période d'investissement.
- **Frais de transaction** : Nous intégrons des frais de transaction fixes et proportionnels pour chaque opération d'achat ou de vente. Ces frais sont déduits du capital disponible à chaque transaction, impactant ainsi la valeur nette du portefeuille.
- **Rebalancement périodique** : Le portefeuille est rebalancé à intervalles réguliers (par exemple, quotidiennement ou hebdomadairement) pour ajuster les poids des actifs conformément aux décisions de l'agent.
- **Espace d'action continue**
- **Pas de glissement (slippage)** : Le glissement est la différence entre le prix attendu auquel un ordre est passé et le prix réel auquel la transaction est effectuée. Ce phénomène est fréquent sur les marchés volatils ou lors de la négociation d'actifs dont la liquidité est limitée. Nous supposons que les actifs négociés de notre portefeuille présentent une liquidité importante, permettant des transactions instantanées aux prix du marché, réduisant ainsi l'impact du glissement.

Mesures d'évaluation de Performance

- **Rendement annualisé** : indicateur financier qui exprime, sur une base annuelle, le taux de croissance moyen d'un investissement en tenant compte de l'effet de la capitalisation des gains ou pertes sur la période considérée.

$$R_{ann} = \left(\frac{V_f}{V_i} \right)^{\frac{1}{T}} - 1 \quad (2.20)$$

Avec :

- V_f : valeur finale de l'investissement,
- V_i : valeur initiale de l'investissement,
- T : durée de l'investissement exprimée en années.

- **Volatilité annualisée** : écart-type des rendements du portefeuille, rapporté sur une base annuelle. Elle permet d'évaluer le risque global du portefeuille.
- **Ratio de Sharpe** : mesure la performance excédentaire d'un portefeuille par unité de risque pris. Il est défini comme le rapport entre le rendement excédentaire du portefeuille et sa volatilité annualisée :

$$S = \frac{R_p - R_f}{\sigma_p} \quad (2.21)$$

Avec :

- R_p : rendement annualisé du portefeuille,
- R_f : taux sans risque annualisé,
- σ_p : volatilité annualisée du portefeuille.

- **Ratio de Sortino** : variante du ratio de Sharpe qui mesure la performance excédentaire d'un portefeuille par unité de risque à la baisse. Il est défini comme :

$$S_o = \frac{R_p - R_f}{\sigma_d} \quad (2.22)$$

Avec :

- R_p : rendement annualisé du portefeuille,
- R_f : taux sans risque annualisé,
- σ_d : volatilité à la baisse (downside deviation), calculée uniquement sur les rendements inférieurs au seuil choisi (souvent R_f).
- **Ratio Calmar** : est un indicateur de performance ajusté au risque. Il se définit comme le rapport entre le taux de rendement annuel moyen d'un investissement et sa perte maximale historique (Maximum Drawdown, MDD) sur la même période :

$$Calmar = \frac{R_{ann}}{MDD} \quad (2.23)$$

avec :

- R_{ann} : rendement annualisé du portefeuille,
- MDD : perte maximale historique du portefeuille, exprimée en valeur absolue ou en pourcentage.

Un ratio de Calmar élevé indique une performance solide par rapport au risque de perte maximale, ce qui est généralement souhaitable pour les investisseurs. Le ratio de Calmar est particulièrement apprécié pour comparer des stratégies d'investissement dans des environnements volatils, car il met l'accent sur la protection du capital face aux baisses importantes. Cependant, il se limite à l'évaluation du risque historique et ne prend pas en compte les risques futurs ou les distributions asymétriques des rendements.

- **Maximum Drawdown** : ou perte maximale, est une mesure du risque de perte extrême d'un investissement sur une période donnée. Il correspond à la plus grande baisse cumulative du portefeuille entre un pic (valeur maximale atteinte) et un creux (valeur minimale) avant qu'un nouveau pic soit atteint.

$$MDD = (VLB/VLH - 1) * 100 \quad (2.24)$$

avec :

- VLB : valeur la plus basse du portefeuille,
- VLH : valeur la plus haute du portefeuille.

Le résultat est exprimé en pourcentage mais il peut être aussi exprimé en valeur absolue. Le MDD est essentiel pour évaluer la résilience d'un portefeuille face aux marchés baissiers : plus il est faible, moins l'investisseur a subi de pertes importantes.

- **Rendement final du portefeuille** : valeur totale du portefeuille à la fin de la période d'investissement.

2.3.4 Modèles de référence (benchmarks)

Pour évaluer la performance de notre approche, les résultats sont comparés à plusieurs stratégies classiques de référence couramment utilisés dans la littérature financière ainsi qu'à un indice de marché, afin de disposer de références solides et pertinentes.

- **Stratégie de Buy and Hold (B&H)** : stratégie passive consistant à investir initialement dans les actifs sélectionnés et à les conserver pendant toute la période d'analyse, sans rééquilibrage.
- **Stratégie d'allocation égale (Equal Weight, EW)** : chaque actif du portefeuille reçoit un poids égal, indépendamment de sa capitalisation boursière ou de ses caractéristiques individuelles. Cette approche vise à maximiser la diversification et à minimiser le risque spécifique à chaque actif.

Formule :

$$w_i = \frac{1}{N}, \quad \forall i \in \{1, 2, \dots, N\} \quad (2.25)$$

avec N le nombre total d'actifs dans le portefeuille. C'est alors une stratégie simple mais efficace, particulièrement adaptée aux marchés où les informations sur les actifs sont limitées ou peu fiables. Elle permet d'évaluer l'intérêt de méthodes d'optimisation ou dynamiques par rapport à une approche uniforme.

- **Stratégie d'optimisation de Markowitz (Mean-Variance Optimization, MVO) :** approche d'optimisation visant à maximiser le rendement attendu pour un niveau de risque donné ou à minimiser le risque pour un rendement cible.

Formule :

$$\begin{aligned} &\text{Minimiser} \quad \mathbf{w}^T \Sigma \mathbf{w} \\ &\text{sous les contraintes} \quad \mathbf{w}^T \mathbf{1} = 1 \\ &\quad \mathbf{w} \geq 0 \end{aligned} \quad (2.26)$$

avec $\mathbf{w}$ le vecteur des poids des actifs, Σ la matrice de covariance des rendements, et $\mathbf{1}$ un vecteur de uns. Cette stratégie est un standard dans la gestion de portefeuille, permettant d'évaluer l'efficacité des approches dynamiques ou basées sur l'apprentissage par renforcement.

- **Indice de marché (BRVM Prestige) :** utilisé comme benchmark pour évaluer la performance relative du portefeuille géré par l'agent RL. L'indice BRVM Prestige est un indice boursier de référence pour la Bourse Régionale des Valeurs Mobilières (BRVM), qui regroupe les principales actions cotées sur cette bourse. Il est conçu pour refléter la performance globale du marché boursier ouest-africain, en se concentrant sur les entreprises les plus importantes et les plus liquides. L'indice BRVM Prestige est calculé en temps réel et mis à jour régulièrement pour fournir une mesure précise de l'évolution des prix des actions qui le composent. Il sert de benchmark pour les investisseurs et les gestionnaires de portefeuille, leur permettant d'évaluer la performance de leurs investissements par rapport au marché global. En tant qu'indice de référence, le BRVM Prestige joue un rôle crucial dans le développement du marché financier ouest-africain, en attirant l'attention des investisseurs locaux et internationaux sur les opportunités offertes par cette région.

Cette comparaison offre une base objective pour apprécier l'efficacité et la robustesse de notre méthodologie, en confrontant la stratégie dynamique à des modèles passifs, optimisés ou systématiques.

2.3.5 Protocole d'entraînement, validation et test

Pour assurer une évaluation rigoureuse des performances, le modèle d'apprentissage par renforcement ainsi que les modèles concurrents ont été traités comme suit :

- **Entraînement du modèle RL :** sur les données comprises entre le 1er janvier 2018 et le 31 décembre 2022, afin que l'agent apprenne les stratégies optimales à partir d'un historique représentatif.
- **Validation du modèle RL :** sur les données du 1er janvier 2023 au 31 décembre 2023, permettant de régler les hyperparamètres et d'éviter le surapprentissage.
- **Test et comparaison finale :** sur les données du 1er janvier 2024 au 31 décembre 2024, période sur laquelle le modèle RL et les modèles concurrents (*Buy & Hold*, *Markowitz*, *Equal Weight*) ont été évalués, ainsi que l'indice *BRVM Prestige*, pour une comparaison objective et réaliste des performances.

Cette séparation temporelle garantit que le modèle RL n'a pas accès aux données de test lors de l'apprentissage, assurant une évaluation honnête et la validité statistique des résultats.

2.4 Conclusion

Ce chapitre met en lumière la cohérence systémique de l'approche méthodologique adoptée. Plutôt que de se limiter à la collecte et au traitement de données, il illustre comment chaque choix – de la sélection des actifs à la modélisation de la dépendance et à l'apprentissage par renforcement – contribue à créer un système intégré de prise de décision pour la gestion de portefeuille.

La méthodologie développée ne se contente pas de traiter les séries financières ; elle les transforme en un espace d'action structuré et exploitable, permettant à l'agent d'apprendre des stratégies optimales dans un contexte réaliste. Cette approche met également en avant l'importance de la flexibilité et de l'adaptabilité des outils utilisés, préparant le terrain pour une analyse empirique rigoureuse et des résultats robustes, tout en soulignant le potentiel de généralisation de la méthodologie à d'autres marchés ou configurations financières.

CHAPITRE

3

RÉSULTATS ET DISCUSSION

Contenu

3.1	Introduction	42
-----	------------------------------	----

3.1 Introduction

Cette section présente les résultats obtenus à partir de l'application de la méthodologie développée et propose une analyse critique de ces résultats. L'objectif n'est pas seulement de rapporter des chiffres, mais de comprendre comment le modèle d'apprentissage par renforcement se comporte face aux modèles concurrents (Buy & Hold, Markowitz, Equal Weight) et à l'indice de référence BRVM Prestige.

Les performances sont évaluées sur la période de test, permettant de mesurer la capacité du modèle à généraliser ses stratégies à de nouvelles données. Chaque indicateur de performance – rendement, risque, ratios financiers – est interprété pour identifier les forces, les limites et les implications pratiques de l'approche. Cette analyse comparative fournit également des enseignements sur l'intérêt de l'intégration de la modélisation de la dépendance via les copules et de l'apprentissage par renforcement dans la gestion de portefeuille.

Ainsi, cette section offre une lecture complète et critique des résultats, mettant en évidence la valeur ajoutée de la méthodologie proposée et permettant de situer ses performances dans le contexte des stratégies classiques et des indices de marché.



ANNEXES

A.1 Démonstrations mathématiques complémentaires

A.1.1 Démonstration de l'équation de Bellman pour la fonction de valeur

Dans le corps du mémoire, nous avons présenté l'équation de Bellman comme un résultat fondamental de l'apprentissage par renforcement. Pour plus de rigueur, cette annexe détaille la démonstration mathématique complète de cette équation, en partant de la définition formelle de la fonction de valeur sous une politique π . Ce développement permet de comprendre comment l'expression récursive reliant $V_\pi(s)$ à la valeur des états suivants découle directement des propriétés de Markov et de la loi totale de l'espérance.

On part de la définition de la fonction de valeur au temps t :

$$V_\pi(s) = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s \right]. \quad (\text{A.1})$$

Étape 1 : Séparation du premier terme. On isole le terme $k = 0$ de la somme, qui correspond à la récompense immédiate :

$$\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} = R_{t+1} + \sum_{k=1}^{\infty} \gamma^k R_{t+k+1}.$$

Étape 2 : Factorisation du facteur γ . En posant $m = k - 1$, on réécrit la somme résiduelle :

$$\sum_{k=1}^{\infty} \gamma^k R_{t+k+1} = \gamma \sum_{m=0}^{\infty} \gamma^m R_{(t+1)+m+1}.$$

Or, la somme

$$\sum_{m=0}^{\infty} \gamma^m R_{(t+1)+m+1}$$

n'est autre que la définition de V_π évaluée à l'état suivant S_{t+1} . Ainsi,

$$\sum_{k=1}^{\infty} \gamma^k R_{t+k+1} = \gamma V_\pi(S_{t+1}).$$

Étape 3 : Substitution dans la définition. En réinjectant ce résultat dans (A.1) et en prenant l'espérance conditionnelle, on obtient :

$$V_\pi(s) = \mathbb{E}_\pi \left[R_{t+1} + \gamma V_\pi(S_{t+1}) \mid S_t = s \right]. \quad (\text{A.2})$$

Étape 4 : Conditionnement sur l'action. En utilisant la loi totale de l'espérance, on introduit l'action A_t choisie selon la politique π :

$$V_\pi(s) = \sum_{a \in A} \mathbb{P}(A_t = a \mid S_t = s) \underbrace{\mathbb{E} \left[R_{t+1} + \gamma V_\pi(S_{t+1}) \mid S_t = s, A_t = a \right]}_{q_\pi(s,a)},$$

où l'on définit la fonction d'action-valeur comme :

$$q_\pi(s, a) = \mathbb{E} \left[R_{t+1} + \gamma V_\pi(S_{t+1}) \mid S_t = s, A_t = a \right].$$

Ainsi, on peut réécrire :

$$V_\pi(s) = \sum_{a \in A} \mathbb{P}(A_t = a \mid S_t = s) q_\pi(s, a).$$

Or la probabilité de choisir l'action a dans l'état s selon la politique π est exactement $\pi(s, a)$, donc on obtient :

$$V_\pi(s) = \sum_{a \in A} \pi(s, a) q_\pi(s, a). \quad (\text{A.3})$$

Étape 5 : Conditionnement sur l'état suivant. En introduisant les probabilités de transition $P(s, a, s') = \Pr(S_{t+1} = s' \mid S_t = s, A_t = a)$ et les récompenses associées $R(s, a, s')$, on obtient :

$$q_\pi(s, a) = \mathbb{E} \left[R_{t+1} + \gamma V_\pi(S_{t+1}) \mid S_t = s, A_t = a \right] = \sum_{s' \in S} P(s, a, s') \left[R(s, a, s') + \gamma V_\pi(s') \right]. \quad (\text{A.4})$$

Étape 6 : Forme finale. En combinant les étapes précédentes, on obtient l'équation de Bellman pour la fonction de valeur d'une politique π :

$$\boxed{V_\pi(s) = \sum_{a \in A} \pi(s, a) \sum_{s' \in S} P(s, a, s') \left[R(s, a, s') + \gamma V_\pi(s') \right].} \quad (\text{A.5})$$

A.1.2 Démonstration de l'équation de Bellman pour la fonction d'action-valeur

Étape 1 : Définition de la fonction d'action-valeur La fonction d'action-valeur sous la politique π est définie par :

$$Q_\pi(s, a) = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s, A_t = a \right]. \quad (\text{A.6})$$

Étape 2 : Séparation de la récompense immédiate On isole le premier terme de la somme ($k = 0$) :

$$\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} = R_{t+1} + \sum_{k=1}^{\infty} \gamma^k R_{t+k+1}.$$

Étape 3 : Factorisation du facteur γ En posant $m = k - 1$:

$$\sum_{k=1}^{\infty} \gamma^k R_{t+k+1} = \gamma \sum_{m=0}^{\infty} \gamma^m R_{t+1+m+1} = \gamma V_\pi(S_{t+1}),$$

où $V_\pi(S_{t+1})$ est la fonction de valeur au prochain état.

Étape 4 : Espérance conditionnelle On prend l'espérance conditionnelle donnée $S_t = s$ et $A_t = a$:

$$Q_\pi(s, a) = \mathbb{E} \left[R_{t+1} + \gamma V_\pi(S_{t+1}) \mid S_t = s, A_t = a \right]. \quad (\text{A.7})$$

Étape 5 : Substitution de la fonction de valeur par sa définition via Q_π On rappelle que :

$$V_\pi(s') = \sum_{a' \in A} \pi(s', a') Q_\pi(s', a').$$

En substituant dans l'expression précédente :

$$Q_\pi(s, a) = \mathbb{E} \left[R_{t+1} + \gamma \sum_{a' \in A} \pi(S_{t+1}, a') Q_\pi(S_{t+1}, a') \mid S_t = s, A_t = a \right].$$

Étape 6 : Conditionnement sur l'état suivant S_{t+1} En introduisant les probabilités de transition $P(s, a, s') = \Pr(S_{t+1} = s' \mid S_t = s, A_t = a)$ et les récompenses $R(s, a, s')$:

$$\mathbb{E} \left[R_{t+1} + \gamma \sum_{a' \in A} \pi(S_{t+1}, a') Q_\pi(S_{t+1}, a') \mid S_t = s, A_t = a \right] = \sum_{s' \in S} P(s, a, s') \left[R(s, a, s') + \gamma \sum_{a' \in A} \pi(s', a') Q_\pi(s', a') \right].$$

Étape 7 : Forme finale (équation de Bellman pour Q_π)

$$Q_\pi(s, a) = \sum_{s' \in S} P(s, a, s') \left[R(s, a, s') + \gamma \sum_{a' \in A} \pi(s', a') Q_\pi(s', a') \right] \quad (\text{A.8})$$

A.2 Modèles

A.2.1 Modèle ARMA

Le modèle ARMA(Autoregressive Moving Average) combine deux composantes :

- **AR(p) : auto-régressif**, qui exprime la valeur actuelle en fonction de ses p valeurs passées.
- **MA(q) : moyenne mobile**, qui modélise la valeur actuelle en fonction des q chocs passés (ou résidus).

Ainsi, la série X_t s'écrit :

$$X_t = \underbrace{\phi_1 X_{t-1} + \phi_2 X_{t-2} + \dots + \phi_p X_{t-p}}_{\text{Partie AR (auto-régressive)}} + \underbrace{\varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}}_{\text{Partie MA (moyenne mobile)}}, \quad (\text{A.9})$$

où :

- X_t : valeur de la série à l'instant t ,
- ϕ_i : coefficients auto-régressifs,
- p : ordre de la partie AR,
- ε_t : bruit blanc (innovation) à l'instant t ,
- θ_j : coefficients de la moyenne mobile,
- q : ordre de la partie MA.

Le modèle ARMA est noté ARMA(p,q) où p et q sont les ordres des parties AR et MA respectivement.

A.2.2 Modèle GJR-GARCH

Le modèle GJR-GARCH(p,q) constitue une extension du modèle GARCH classique, permettant de prendre en compte l'asymétrie des chocs : les mauvaises nouvelles ont généralement un impact plus marqué sur la volatilité que les bonnes. Cette spécificité permet de mieux modéliser la dynamique de la volatilité conditionnelle.

$$\sigma_t^2 = \omega + \sum_{i=1}^p \alpha_i \varepsilon_{t-i}^2 + \sum_{i=1}^p \gamma_i \varepsilon_{t-i}^2 \mathbf{1}_{\{\varepsilon_{t-i} < 0\}} + \sum_{j=1}^q \beta_j \sigma_{t-j}^2 \quad (\text{A.10})$$

où :

- σ_t^2 : variance conditionnelle à l'instant t ,
- ω : terme constant,
- α_i : coefficients des innovations passées ε_{t-i}^2 ,
- γ_i : coefficients capturant l'effet asymétrique,
- β_j : coefficients des variances passées,
- $\mathbf{1}_{\{\varepsilon_{t-i} < 0\}}$: indicatrice valant 1 si $\varepsilon_{t-i} < 0$, sinon 0.

A.2.3 SAC(Soft Actor Critic)

Objectif entropique

L'originalité de SAC réside dans l'introduction d'un **terme d'entropie** dans la fonction objectif. Ce mécanisme incite l'agent à adopter des actions diversifiées, réduisant le risque de se coincer dans des stratégies sous-optimales et favorisant l'exploration de l'environnement. La fonction objectif de l'agent est alors :

$$J(\pi) = \sum_{t=0}^{\infty} \mathbb{E}_{(s_t, a_t) \sim \rho_{\pi}} \left[R(s_t, a_t) + \alpha H(\pi(\cdot | s_t)) \right] \quad (\text{A.11})$$

où $H(\pi(\cdot | s_t)) = -\mathbb{E}_{a_t \sim \pi} [\log \pi(a_t | s_t)]$ désigne l'entropie de la politique. Le paramètre α , appelé **température**, contrôle le compromis entre maximisation de la récompense (exploitation) et maintien d'une politique stochastique (exploration). Cette formulation permet à l'agent de maintenir un équilibre entre exploitation des actions connues et exploration de nouvelles stratégies, un atout majeur pour la gestion de portefeuille dans des environnements financiers complexes et dynamiques.

Architecture du modèle

SAC est un algorithme de **Deep Reinforcement Learning** car il repose sur l'utilisation de réseaux de neurones profonds pour approximer les fonctions de valeur et la politique. Ces réseaux jouent un rôle central dans la capacité de l'agent à généraliser et à prendre des décisions dans des espaces d'état et d'action de grande dimension.

- **Deux réseaux Critic**, notés Q_{θ_1} et Q_{θ_2} , qui approximent la fonction d'action-valeur $Q(s, a)$. Leur rôle est d'estimer la qualité d'une action donnée a dans un état s . L'utilisation de deux estimateurs distincts permet de réduire le biais d'optimisme rencontré dans les méthodes de type Q-learning, ce qui contribue à une meilleure stabilité de l'entraînement.
- **Un réseau Actor**, noté $\pi_{\phi}(a | s)$, qui représente la politique stochastique de l'agent. Dans SAC, cette politique est modélisée comme une distribution gaussienne dont les paramètres (moyenne $\mu_{\phi}(s)$ et écart-type $\sigma_{\phi}(s)$) sont prédits par un réseau de neurones. L'action est ensuite obtenue par échantillonnage de cette distribution, puis transformée (par exemple via une fonction tanh) pour respecter les contraintes de bornes sur l'espace des actions.
- **Un réseau de valeur**, noté $V_{\psi}(s)$, utilisé dans certaines variantes de SAC, qui approxime directement la valeur d'un état. Dans les implémentations modernes, ce réseau peut être remplacé par une combinaison des deux réseaux Q , ce qui simplifie l'architecture.

Replay buffer : L'algorithme SAC est *off-policy*, ce qui signifie qu'il peut apprendre à partir d'expériences passées qui ne proviennent pas nécessairement de la politique actuelle. Ces expériences sont stockées dans une mémoire appelée **replay buffer**. Concrètement, à chaque interaction avec l'environnement, une transition (s_t, a_t, r_t, s_{t+1}) est ajoutée au buffer. Lors de l'entraînement, les réseaux de neurones ne sont pas mis à jour avec la dernière transition uniquement, mais à partir de mini-lots (*mini-batches*) de transitions tirées aléatoirement dans le buffer. Cette approche présente deux avantages majeurs :

- elle **brise la corrélation temporelle** entre les données successives, ce qui rend l'apprentissage plus stable ;
- elle **améliore l'efficacité de l'échantillonnage**, car chaque transition peut être réutilisée plusieurs fois pour mettre à jour les paramètres des réseaux.

Rétropropagation : Les différents réseaux de neurones utilisés dans SAC sont entraînés par la méthode de **rétropropagation du gradient (backpropagation)**. Cette technique consiste à ajuster les poids et biais des réseaux afin de minimiser une fonction de perte (par exemple, l'erreur quadratique entre la valeur estimée et la valeur cible pour les Critic). Le processus suit deux étapes principales :

- **Propagation avant (forward pass) :** l'entrée (état ou couple (s, a)) est propagée dans le réseau pour produire une sortie (valeur Q , valeur V ou paramètres de la politique).
- **Propagation arrière (backward pass) :** l'erreur entre la sortie prédite et la cible est calculée. Cette erreur est ensuite propagée en sens inverse à travers le réseau à l'aide de la règle de la chaîne, afin de calculer les gradients des poids par rapport à la fonction de perte.

Une fois les gradients obtenus, les paramètres du réseau sont mis à jour grâce à un optimiseur numérique, comme **Adam**, qui applique la descente de gradient stochastique avec ajustement adaptatif du taux d'apprentissage.

Ainsi, l'architecture SAC combine de manière cohérente :

- des réseaux profonds (permettant de traiter des espaces d'états et d'actions complexes) ;
- une mémoire d'expériences (replay buffer) garantissant un apprentissage plus stable et efficace ;
- la rétropropagation du gradient pour mettre à jour les paramètres et améliorer progressivement la performance de l'agent.

Mise à jour

• Critic (Q-functions)

Dans SAC, on approxime la fonction Q avec un réseau neuronal paramétré par θ . Pour entraîner ce réseau, on définit une fonction de perte quadratique basée sur la différence entre l'estimation du réseau et une cible issue de la relation de Bellman :

$$J_Q(\theta) = \mathbb{E}_{(s_t, a_t) \sim D} \left[\frac{1}{2} \left(Q_\theta(s_t, a_t) - \hat{Q}(s_t, a_t) \right)^2 \right], \quad (\text{A.12})$$

où :

- $Q_\theta(s_t, a_t)$: valeur estimée par le Q-network pour l'état-action (s_t, a_t) .
- $\hat{Q}(s_t, a_t)$: valeur cible, représentant la "vérité" que le réseau doit apprendre.
La cible Q est dérivée de la relation de Bellman avec entropie, car l'agent cherche à maximiser à la fois la récompense et l'entropie de la politique :

$$\hat{Q}(s_t, a_t) = R_{t+1} + \gamma \mathbb{E}_{s_{t+1} \sim p} [V_{\bar{\psi}}(s_{t+1})] \quad (\text{A.13})$$

Avec

$$V_{\bar{\psi}}(s_{t+1}) = \mathbb{E}_{a_{t+1} \sim \pi_\phi} [Q_{\bar{\theta}}(s_{t+1}, a_{t+1}) - \alpha \log \pi_\phi(a_{t+1} | s_{t+1})] \quad (\text{A.14})$$

où :

- $V_{\bar{\psi}}$: réseau de valeur cible, avec des paramètres $\bar{\psi}$
- $Q_{\bar{\theta}}$: copie du Q-network avec des paramètres $\bar{\theta}$
- D : buffer de replay, qui stocke les transitions (s_t, a_t, r_t, s_{t+1}) .

Le gradient de la fonction de perte $J_Q(\theta)$ par rapport aux paramètres θ s'écrit :

$$\nabla_{\theta} J_Q(\theta) = \nabla_{\theta} \mathbb{E}_{(s_t, a_t) \sim D} \left[\frac{1}{2} (Q_{\theta}(s_t, a_t) - \hat{Q}(s_t, a_t))^2 \right] \quad (\text{A.15})$$

$$= \mathbb{E}_{(s_t, a_t) \sim D} \left[(Q_{\theta}(s_t, a_t) - \hat{Q}(s_t, a_t)) \nabla_{\theta} Q_{\theta}(s_t, a_t) \right]. \quad (\text{A.16})$$

Ce gradient est utilisé pour mettre à jour les paramètres θ du réseau Critic selon la formule suivante :

$$\theta \leftarrow \theta - \eta_{\theta} \hat{\nabla}_{\theta} J_Q(\theta) \quad (\text{A.17})$$

où η_{θ} représente le taux d'apprentissage.

• Value function

Dans l'algorithme **Soft Actor-Critic (SAC)**, on introduit explicitement une fonction de valeur $V_{\psi}(s)$, paramétrée par ψ , définie comme suit :

$$V_{\psi}(s) \approx \mathbb{E}_{a \sim \pi(\cdot|s)} \left[Q_{\theta}(s, a) - \alpha \log \pi(a|s) \right], \quad (\text{A.18})$$

où Q_{θ} désigne l'estimateur de la fonction de valeur d'action, π est la politique stochastique et α est le coefficient de température qui pondère l'entropie. L'objectif de $V_{\psi}(s)$ est donc d'estimer l'espérance du couple $(Q - \alpha \log \pi)$ sous la politique courante.

Définition de la cible

La cible utilisée pour entraîner V_{ψ} est donnée par :

$$\hat{V}(s) = \mathbb{E}_{a \sim \pi(\cdot|s)} \left[\min_{i \in \{1, 2\}} Q_{\bar{\theta}_i}(s, a) - \alpha \log \pi(a|s) \right], \quad (\text{A.19})$$

où $Q_{\bar{\theta}_1}, Q_{\bar{\theta}_2}$ sont deux estimateurs de Q avec des paramètres cibles gelés (target networks). Le terme $\min(Q_{\bar{\theta}_1}, Q_{\bar{\theta}_2})$ permet de réduire le biais positif d'approximation.

Fonction de perte et mise à jour

La fonction de valeur est apprise en minimisant l'erreur quadratique entre sa sortie et la cible :

$$J_V(\psi) = \mathbb{E}_{s_t \sim D} \left[\frac{1}{2} \left(V_{\psi}(s_t) - \mathbb{E}_{a_t \sim \pi_{\phi}} [Q_{\theta}(s_t, a_t) - \alpha \log \pi_{\phi}(a_t|s_t)] \right)^2 \right] \quad (\text{A.20})$$

Dérivation du gradient

En dérivant la perte (A.20) par rapport aux paramètres ψ , on obtient :

$$\begin{aligned}\nabla_{\psi} J_V(\psi) &= \nabla_{\psi} \mathbb{E}_{s \sim \mathcal{D}} \left[\frac{1}{2} \left(V_{\psi}(s) - \widehat{V}(s) \right)^2 \right] \\ &= \mathbb{E}_{s \sim \mathcal{D}} \left[\left(V_{\psi}(s) - \widehat{V}(s) \right) \nabla_{\psi} V_{\psi}(s) \right].\end{aligned}\quad (\text{A.21})$$

La mise à jour des paramètres ψ s'écrit alors :

$$\psi \leftarrow \psi - \eta_V \widehat{\nabla}_{\psi} J_V(\psi), \quad (\text{A.22})$$

où η_V est le taux d'apprentissage.

- **Policy (Actor)**

Le rôle de l'Actor est de définir la politique stochastique $\pi_{\phi}(a|s)$, qui indique comment l'agent choisit ses actions en fonction de l'état courant. Contrairement à une politique déterministe, cette approche introduit de l'exploration et rend possible l'optimisation directe via le gradient de politique.

Objectif initial avec entropie

Dans le cadre du *maximum entropy reinforcement learning*, l'objectif à optimiser est :

$$J(\pi) = \sum_{t=0}^{\infty} \mathbb{E}_{(s_t, a_t) \sim \rho_{\pi}} \left[R(s_t, a_t) + \alpha H(\pi(\cdot|s_t)) \right], \quad (\text{A.23})$$

où $R(s_t, a_t)$ est la récompense immédiate et $H(\pi(\cdot|s_t)) = -\mathbb{E}_{a_t \sim \pi} [\log \pi(a_t|s_t)]$ désigne l'entropie de la politique. Le terme α pondère le compromis entre exploitation (récompenses élevées) et exploration (entropie élevée).

Passage vers la fonction Q

Pour rendre (A.23) calculable, on introduit la fonction action-valeur :

$$Q^{\pi}(s_t, a_t) = \mathbb{E}_{\rho_{\pi}} \left[R(s_t, a_t) + \gamma V^{\pi}(s_{t+1}) \right]. \quad (\text{A.24})$$

Ainsi, au lieu de raisonner sur des sommes infinies de récompenses, on reformule l'objectif de la politique comme :

$$J(\pi_{\phi}) = \mathbb{E}_{s_t \sim D, a_t \sim \pi_{\phi}} \left[Q_{\theta}(s_t, a_t) - \alpha \log \pi_{\phi}(a_t|s_t) \right]. \quad (\text{A.25})$$

Cette équation exprime que l'Actor doit à la fois :

- * favoriser les actions ayant une haute valeur selon le Critic ($Q_{\theta}(s, a)$),
- * maintenir une politique stochastique par l'entropie (via $-\alpha \log \pi_{\phi}$).

Paramétrisation gaussienne de la politique

Dans SAC, la politique est modélisée par une loi normale multivariée :

$$a_t \sim \mathcal{N}(\mu_\phi(s_t), \text{diag}(\sigma_\phi^2(s_t))). \quad (\text{A.26})$$

- * $\mu_\phi(s_t)$: moyenne prédite par le réseau Actor pour l'état s_t , représentant l'action la plus probable.
- * $\sigma_\phi(s_t)$: écart-type appris, qui détermine l'ampleur de l'exploration.
- * $\text{diag}(\sigma_\phi^2(s_t))$: covariance diagonale (hypothèse d'indépendance des dimensions de l'action).

La loi normale est choisie car elle est simple, différentiable, et adaptée aux espaces d'actions continues. Elle permet aussi un contrôle explicite de la balance entre exploitation (μ_ϕ) et exploration (σ_ϕ).

Reparamétrisation

Un défi apparaît : échantillonner directement $a_t \sim \pi_\phi$ rend le calcul du gradient impossible. On utilise alors le *reparametrization trick* :

$$a_t = \tanh(\mu_\phi(s_t) + \sigma_\phi(s_t) \odot \varepsilon), \quad \varepsilon \sim \mathcal{N}(0, I). \quad (\text{A.27})$$

De cette manière :

- * l'aléa provient uniquement de ε , indépendant des paramètres,
- * μ_ϕ et σ_ϕ restent différentiables,
- * la fonction $\tanh$ assure que les actions restent bornées dans $[-1, 1]$.

Fonction de perte de l'Actor

En pratique, on entraîne l'Actor en minimisant l'opposé de (A.25) :

$$J_\pi(\phi) = \mathbb{E}_{s_t \sim D, \varepsilon \sim \mathcal{N}} \left[\alpha \log \pi_\phi(f_\phi(\varepsilon; s_t) | s_t) - Q_\theta(s_t, f_\phi(\varepsilon; s_t)) \right], \quad (\text{A.28})$$

avec $f_\phi(\varepsilon; s_t) = \mu_\phi(s_t) + \sigma_\phi(s_t) \odot \varepsilon$.

Mise à jour des paramètres

Après avoir défini la fonction de perte $J_\pi(\phi)$, les paramètres de l'Actor sont mis à jour via descente de gradient stochastique :

$$\phi \leftarrow \phi - \eta_\phi \hat{\nabla}_\phi J_\pi(\phi), \quad (\text{A.29})$$

où :

- * ϕ : paramètres du réseau Actor,
- * η_ϕ : taux d'apprentissage de l'Actor,
- * $\hat{\nabla}_\phi J_\pi(\phi)$: gradient estimé sur un mini-batch de transitions (s_t, a_t, r_t, s_{t+1}) .

Le gradient de $J_\pi(\phi)$ met à jour ϕ de manière à :

- * augmenter la probabilité des actions ayant une valeur $Q_\theta(s, a)$ élevée,
- * maintenir une entropie suffisante via le terme $\alpha \log \pi_\phi$.

- **Température adaptative**

Dans certaines implémentations, on choisit un α constant, ce qui simplifie l'algorithme mais, si sa valeur est mal choisie, l'agent peut explorer trop peu ou trop, ralentissant ainsi l'apprentissage.

Plus moderne et robuste, l'agent ajuste automatiquement α pour maintenir une entropie cible H_{target} , adaptant ainsi l'exploration à l'évolution de l'apprentissage et à la complexité de l'environnement. Le paramètre α est appris automatiquement via :

$$J(\alpha) = \mathbb{E}_{a_t \sim \pi_\phi} \left[-\alpha (\log \pi_\phi(a_t | s_t) + H_{\text{target}}) \right]. \quad (\text{A.30})$$

Mise à jour de α

On effectue une descente de gradient sur $J(\alpha)$:

$$\alpha \leftarrow \alpha - \eta_\alpha \nabla_\alpha J(\alpha), \quad (\text{A.31})$$

où η_α est le taux d'apprentissage de la température.

- **Mise à jour des Target Networks**

Pour stabiliser l'apprentissage des Critic networks et éviter que les cibles Q changent trop brutalement, SAC utilise des Target Networks $\bar{\theta}_1, \bar{\theta}_2$:

$$\bar{\theta}_j \leftarrow \tau \theta_j + (1 - \tau) \bar{\theta}_j, \quad j = 1, 2, \quad (\text{A.32})$$

où :

- * θ_j : paramètres actuels du Critic Q_{θ_j} ,
- * $\bar{\theta}_j$: paramètres du Critic cible,
- * $\tau \in [0, 1]$: coefficient de mise à jour “douce”.

Cette mise à jour “douce”(soft update aussi appelé **Polyak averaging**) assure que les cibles $\min(Q_{\bar{\theta}_1}, Q_{\bar{\theta}_2})$ utilisées pour entraîner l'Actor et le Critic évoluent progressivement, ce qui réduit les oscillations et améliore la stabilité de l'apprentissage.

Algorithme SAC

L'algorithme s'exécute selon les étapes suivantes :

1. Initialiser les réseaux $Q_{\theta_1}, Q_{\theta_2}, V_\psi, \pi_\phi$ et le *replay buffer*.
2. À chaque étape, observer l'état s_t et sélectionner une action $a_t \sim \pi_\phi(\cdot | s_t)$.
3. Exécuter a_t , recevoir la récompense r_t et l'état suivant s_{t+1} .
4. Stocker (s_t, a_t, r_t, s_{t+1}) dans le *replay buffer*.
5. Échantillonner un mini-lot de transitions et mettre à jour successivement :
 - les deux réseaux Critic $Q_{\theta_1}, Q_{\theta_2}$,

- le réseau de valeur V_ψ ,
- le réseau Actor π_ϕ ,
- la température α .

6. Mettre à jour les réseaux cibles par *polyak averaging*.

Il est à noter que la majorité des équations et formulations de cette section sont issues de l'article original sur le Soft Actor-Critic (HAARNOJA et al., 2018), auquel le lecteur pourra se référer pour plus de détails théoriques.

A.3 Tests statistiques

A.3.1 Test de stationnarité des rendements

On distingue généralement deux notions de stationnarité : la stationnarité **au sens strict (ou forte)** et la stationnarité **au sens faible (ou du second ordre)**.

Stationnarité au sens strict

Une série temporelle $\{X_t\}$ est dite **stationnaire au sens strict** si, pour tout $k \in \mathbb{N}$, pour tout choix d'instants $(t_1, \dots, t_k)$ et pour tout décalage $h \in \mathbb{Z}$, on a :

$$\mathcal{L}(X_{t_1}, \dots, X_{t_k}) = \mathcal{L}(X_{t_1+h}, \dots, X_{t_k+h}) \quad (\text{A.33})$$

c'est-à-dire que la *loi jointe* de la série est invariante par translation dans le temps.

Stationnarité au sens faible

Dans la pratique, on se contente souvent de la stationnarité au sens faible, qui ne fait intervenir que les moments d'ordre 1 et 2. Une série $\{X_t\}$ est **faiblement stationnaire** si :

$$\mathbb{E}[X_t] = \mu \quad \forall t \quad (\text{A.34})$$

$$\text{Var}(X_t) = \mathbb{E}[(X_t - \mu)^2] = \sigma^2 \quad \forall t \quad (\text{A.35})$$

$$\text{Cov}(X_t, X_{t+k}) = \gamma(k) \quad \forall t, k \in \mathbb{Z} \quad (\text{A.36})$$

Autrement dit, la moyenne et la variance sont constantes dans le temps, et la covariance entre deux observations dépend uniquement du *lag* k et non des dates absolues.

La stationnarité des séries peut être vérifiée à l'aide des tests statistiques classiques, tels que Augmented Dickey-Fuller (ADF) et Kwiatkowski-Phillips-Schmidt-Shin (KPSS).

TABLE A.1 – Résumé des tests de stationnarité (ADF et KPSS)

Test	Hypothèses	Règle de décision
ADF (Augmented Dickey-Fuller)	H_0 : la série possède une racine unitaire (non stationnaire) H_1 : la série est stationnaire	Si p -value $\alpha \Rightarrow$ Rejet de H_0 (la série est stationnaire) Si p -value $\geq \alpha \Rightarrow$ On ne rejette pas H_0 (la série est non stationnaire)
KPSS (Kwiatkowski-Phillips-Schmidt-Shin)	H_0 : la série est stationnaire (autour d'une constante ou d'une tendance) H_1 : la série est non stationnaire (présence d'une racine unitaire)	Si p -value $\alpha \Rightarrow$ Rejet de H_0 (la série est non stationnaire) Si p -value $\geq \alpha \Rightarrow$ On ne rejette pas H_0 (la série est stationnaire)

A.3.2 Test de Ljung-Box

Pour vérifier la présence d'autocorrélation dans les rendements, le test de Ljung-Box dont les hypothèses sont résumées dans le tableau ci-dessous peut être utilisé.

TABLE A.2 – Hypothèses et règle de décision du test de Ljung-Box

Hypothèse	Interprétation / Règle de décision
$H_0 : \rho_1 = \rho_2 = \dots = \rho_m = 0$	Absence d'autocorrélation jusqu'au lag m (les résidus sont indépendants). On ne rejette pas H_0 si la p-valeur seuil de signification (ex. 5%).
$H_1 : \exists \rho_k \neq 0$ pour au moins un $k \leq m$	Présence d'autocorrélation significative. On rejette H_0 si la p-valeur $\leq$ seuil de signification (ex. 5%).

A.3.3 Test ARCH d'Engle

Afin de tester l'existence d'hétéroscédasticité conditionnelle (volatilité dépendante du passé), le test d'Engle (ARCH) peut être utilisé. Les hypothèses et la règle de décision sont présentées dans le tableau suivant.

Hypothèse	Interprétation / Règle de décision
H_0 : absence d'effet ARCH	Les résidus ne présentent pas d'hétéroscédasticité conditionnelle. On ne rejette pas H_0 si la p-valeur seuil de signification (ex. 5%).
H_1 : présence d'un effet ARCH	Les résidus présentent une hétéroscédasticité conditionnelle significative. On rejette H_0 si la p-valeur $\leq$ seuil de signification (ex. 5%).

TABLE A.3 – Hypothèses et règle de décision du test d'Engle (ARCH LM test)

A.4 Indicateurs techniques

Voici une liste des indicateurs techniques utilisés dans ce travail, avec une brève description de chacun :

- **Indice de force relative (RSI)**

Le RSI est un indicateur technique de momentum qui mesure la force et la vitesse des variations de prix d'un actif sur une période donnée. Il est calculé à partir du rapport

entre les gains moyens et les pertes moyennes sur n périodes, puis transformé en une échelle de 0 à 100 :

$$RSI = 100 - \frac{100}{1 + RS}, \quad RS = \frac{\text{Gains moyens}}{\text{Pertes moyennes}} \quad (\text{A.37})$$

L'indicateur est largement utilisé pour analyser la dynamique des prix, détecter les excès de marché et affiner les décisions d'investissement.

- **SMA**

La SMA est une moyenne arithmétique des prix d'un actif sur une fenêtre glissante de n périodes. Elle permet de lisser les fluctuations de prix et d'identifier la tendance générale du marché.

$$SMA_t = \frac{1}{n} \sum_{i=0}^{n-1} P_{t-i} \quad (\text{A.38})$$

où P_{t-i} représente le prix de clôture à la période $t - i$, et n est le nombre de périodes choisi.

La SMA est largement utilisée pour :

- * Déterminer les niveaux de support et de résistance,
- * Confirmer la direction de la tendance,
- * Servir de référence pour d'autres indicateurs techniques (par exemple, les Bandes de Bollinger).

- **EMA**

L'EMA est une moyenne mobile pondérée qui donne plus de poids aux prix récents, ce qui la rend plus réactive aux variations récentes du marché comparée à la SMA.

$$EMA_t = \alpha \cdot P_t + (1 - \alpha) \cdot EMA_{t-1} \quad (\text{A.39})$$

où :

- * P_t est le prix de clôture à la période t ,
- * $\alpha = \frac{2}{n+1}$ est le facteur de lissage,
- * n est le nombre de périodes utilisées pour le calcul.

L'EMA est particulièrement utile pour :

- * Identifier rapidement les changements de tendance,
- * Servir de référence dans des indicateurs techniques comme les Bandes de Bollinger ou le MACD,
- * Détecter les signaux d'achat et de vente avec plus de sensibilité que la SMA.

- **MACD**

Le MACD est un indicateur de momentum qui montre la relation entre deux moyennes mobiles exponentielles (EMA) de prix. Il est calculé en soustrayant l'EMA à 26 périodes de l'EMA à 12 périodes :

$$MACD_t = EMA_{12,t} - EMA_{26,t} \quad (\text{A.40})$$

Une ligne de signal, qui est l'EMA à 9 périodes du MACD, est ensuite tracée au-dessus du MACD pour identifier les signaux d'achat et de vente :

$$\text{Signal}_t = EMA_{9,t}(MACD) \quad (\text{A.41})$$

Le MACD est largement utilisé pour :

- * Identifier les changements de tendance,
 - * Détecter les divergences entre le prix et l'indicateur,
 - * Générer des signaux d'achat et de vente basés sur les croisements du MACD et de la ligne de signal.
 - * Évaluer la force et la direction du momentum du marché.
 - * Analyser les tendances à court et moyen terme.
- **Closing Price (lag 1) : Close_Lag1** Le **Close_Lag1** correspond au prix de clôture enregistré *la veille*. Cette valeur permet d'incorporer l'information immédiate passée dans l'analyse afin de mieux comprendre les mouvements récents du marché et d'anticiper les évolutions à court terme.
 - **Closing Price (lag 3) : Close_Lag3** Le **Close_Lag3** représente le prix de clôture observé *trois jours avant* la date considérée. Il fournit une vision légèrement plus étendue de la tendance récente et aide à détecter des variations sur quelques séances plutôt que sur une seule journée.
 - **Closing Price (lag 5) : Close_Lag5** Le **Close_Lag5** correspond au prix de clôture *cinq jours auparavant*. Cette variable retardée permet d'intégrer des informations plus anciennes, utiles pour repérer des effets de persistance et des comportements de marché sur plusieurs jours, ce qui enrichit l'analyse et la modélisation.

Pour avoir des informations plus détaillées sur les indicateurs, le lecteur peut se référer à (*Waldata — Indicateurs techniques pour le trading 2025*).

A.5 Résultats

TABLE A.4 – Résultats des tests de stationnarité (ADF et KPSS) pour l'ensemble des titres

Ticker	ADF p-value	ADF conclusion	KPSS p-value	KPSS conclusion	Conclusion générale
ABJC	0.287266	Non stationnaire	0.01	Non stationnaire	Non stationnaire
BICC	0.984907	Non stationnaire	0.01	Non stationnaire	Non stationnaire
BNBC	0.563740	Non stationnaire	0.01	Non stationnaire	Non stationnaire
BOAB	0.698628	Non stationnaire	0.01	Non stationnaire	Non stationnaire
BOABF	0.346291	Non stationnaire	0.01	Non stationnaire	Non stationnaire
BOAC	0.976901	Non stationnaire	0.01	Non stationnaire	Non stationnaire
BOAM	0.017034	Stationnaire	0.01	Non stationnaire	Inconcluant
BOAN	0.348235	Non stationnaire	0.01	Non stationnaire	Non stationnaire
BOAS	0.978275	Non stationnaire	0.01	Non stationnaire	Non stationnaire
CABC	0.249314	Non stationnaire	0.01	Non stationnaire	Non stationnaire
CBIBF	0.089490	Non stationnaire	0.01	Non stationnaire	Non stationnaire
CFAC	0.506951	Non stationnaire	0.01	Non stationnaire	Non stationnaire
CIEC	0.672753	Non stationnaire	0.01	Non stationnaire	Non stationnaire
ECOC	0.999087	Non stationnaire	0.01	Non stationnaire	Non stationnaire
ETIT	0.000174	Stationnaire	0.01	Non stationnaire	Inconcluant
FTSC	0.288978	Non stationnaire	0.01	Non stationnaire	Non stationnaire
NEIC	0.551846	Non stationnaire	0.01	Non stationnaire	Non stationnaire
NSBC	0.399833	Non stationnaire	0.01	Non stationnaire	Non stationnaire
NTLC	0.997490	Non stationnaire	0.01	Non stationnaire	Non stationnaire
ONTBF	0.533917	Non stationnaire	0.01	Non stationnaire	Non stationnaire

Suite à la page suivante

Table A.4 – suite

Ticker	ADF p-value	ADF conclusion	KPSS p-value	KPSS conclusion	Conclusion générale
ORAC	0.830204	Non stationnaire	0.01	Non stationnaire	Non stationnaire
ORGT	0.923778	Non stationnaire	0.01	Non stationnaire	Non stationnaire
PALC	0.316245	Non stationnaire	0.01	Non stationnaire	Non stationnaire
PRSC	0.187018	Non stationnaire	0.01	Non stationnaire	Non stationnaire
SAFC	0.089700	Non stationnaire	0.01	Non stationnaire	Non stationnaire
SCRC	0.001222	Stationnaire	0.01	Non stationnaire	Inconcluant
SDCC	0.759647	Non stationnaire	0.01	Non stationnaire	Non stationnaire
SDSC	0.482180	Non stationnaire	0.01	Non stationnaire	Non stationnaire
SEMC	0.115739	Non stationnaire	0.01	Non stationnaire	Non stationnaire
SGBC	0.998006	Non stationnaire	0.01	Non stationnaire	Non stationnaire
SHEC	0.280600	Non stationnaire	0.01	Non stationnaire	Non stationnaire
SIBC	0.998548	Non stationnaire	0.01	Non stationnaire	Non stationnaire
SICC	0.038542	Stationnaire	0.01	Non stationnaire	Inconcluant
SIVC	0.336658	Non stationnaire	0.01	Non stationnaire	Non stationnaire
SLBC	0.403690	Non stationnaire	0.01	Non stationnaire	Non stationnaire
SMBC	0.300229	Non stationnaire	0.01	Non stationnaire	Non stationnaire
SNTS	0.720314	Non stationnaire	0.01	Non stationnaire	Non stationnaire
SOGC	0.706218	Non stationnaire	0.01	Non stationnaire	Non stationnaire
SPHC	0.442803	Non stationnaire	0.01	Non stationnaire	Non stationnaire
STAC	0.491922	Non stationnaire	0.01	Non stationnaire	Non stationnaire
STBC	0.999042	Non stationnaire	0.01	Non stationnaire	Non stationnaire
TTLC	0.316327	Non stationnaire	0.01	Non stationnaire	Non stationnaire
TTLS	0.255246	Non stationnaire	0.01	Non stationnaire	Non stationnaire
UNLC	0.185821	Non stationnaire	0.01	Non stationnaire	Non stationnaire
UNXC	0.531131	Non stationnaire	0.01	Non stationnaire	Non stationnaire

Source : Calculs à partir des données de marché.

TABLE A.5 – Résultats des tests de stationnarité (ADF et KPSS) pour l'ensemble des titres

Ticker	ADF p-value	ADF conclusion	KPSS p-value	KPSS conclusion	Conclusion générale
ABJC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
BICC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
BNBC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
BOAB	1.591875e-28	Stationnaire	0.100000	Stationnaire	Stationnaire
BOABF	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
BOAC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
BOAM	9.490373e-30	Stationnaire	0.100000	Stationnaire	Stationnaire
BOAN	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
BOAS	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
CABC	2.459194e-30	Stationnaire	0.100000	Stationnaire	Stationnaire
CBIBF	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
CFAC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
CIEC	5.163723e-30	Stationnaire	0.100000	Stationnaire	Stationnaire
ECOC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
ETIT	1.681133e-28	Stationnaire	0.100000	Stationnaire	Stationnaire
FTSC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
NEIC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire

Suite à la page suivante

Table A.5 – suite

Ticker	ADF p-value	ADF conclusion	KPSS p-value	KPSS conclusion	Conclusion générale
NSBC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
NTLC	4.708232e-24	Stationnaire	0.100000	Stationnaire	Stationnaire
ONTBF	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
ORAC	4.529075e-30	Stationnaire	0.100000	Stationnaire	Stationnaire
ORGT	8.517684e-30	Stationnaire	0.100000	Stationnaire	Stationnaire
PALC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
PRSC	1.370629e-23	Stationnaire	0.100000	Stationnaire	Stationnaire
SAFC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
SCRC	1.138722e-24	Stationnaire	0.071538	Stationnaire	Stationnaire
SDCC	4.807396e-30	Stationnaire	0.100000	Stationnaire	Stationnaire
SDSC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
SEMC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
SGBC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
SHEC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
SIBC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
SICC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
SIVC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
SLBC	1.106364e-26	Stationnaire	0.100000	Stationnaire	Stationnaire
SMBC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
SNTS	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
SOGC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
SPHC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
STAC	9.664407e-25	Stationnaire	0.100000	Stationnaire	Stationnaire
STBC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
TTLC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire
TTLS	2.625523e-30	Stationnaire	0.100000	Stationnaire	Stationnaire
UNLC	1.537965e-20	Stationnaire	0.100000	Stationnaire	Stationnaire
UNXC	0.000000	Stationnaire	0.100000	Stationnaire	Stationnaire

Source : Calculs à partir des données de marché.

RÉFÉRENCES BIBLIOGRAPHIQUES

- AGLIETTA, Michel (2008). *La crise : Pourquoi en est-on arrivé là ? Comment en sortir ?* Paris : Perrin.
- ALOTAIBI, Tahani S., Luciana DALLA VALLE et Matthew J. CRAVEN (2022). « The Worst Case GARCH-Copula CVaR Approach for Portfolio Optimisation : Evidence from Financial Markets ». In : *Journal of Risk and Financial Management* 15.10, p. 482. DOI : [10.3390/jrfm15100482](https://doi.org/10.3390/jrfm15100482).
- ALZAMAN, Chaheer (2024). « Deep learning in stock portfolio selection and predictions ». In : *Expert Systems with Applications* 237, p. 121404. DOI : [10.1016/j.eswa.2023.121404](https://doi.org/10.1016/j.eswa.2023.121404).
- BELLMAN, Richard (1957). « A Markovian Decision Process ». In : *Journal of Mathematics and Mechanics* 6.5. Accessed via gwern.net, p. 679-684. URL : <https://gwern.net/doc/statistics/decision/1957-bellman-dynamicprogramming.pdf>.
- BLACK, Fischer et Robert LITTERMAN (1992). « Global Portfolio Optimization ». In : *Financial Analysts Journal* 48.5, p. 28-43. DOI : [10.2469/faj.v48.n5.28](https://doi.org/10.2469/faj.v48.n5.28). URL : <https://doi.org/10.2469/faj.v48.n5.28>.
- CARHART, Mark M. (1997). « On Persistence in Mutual Fund Performance ». In : *The Journal of Finance* 52.1, p. 57-82. DOI : [10.2307/2329556](https://doi.org/10.2307/2329556). URL : <https://www.jstor.org/stable/2329556>.
- CHATSANGA, Nonthachote et Andrew J. PARKES (2017). « Two-Stage Stochastic International Portfolio Optimisation under Regular-Vine-Copula-Based Scenarios ». In : *arXiv preprint arXiv :1704.01174*. URL : <https://arxiv.org/abs/1704.01174>.
- CHOPRA, Vijay et William T. ZIEMBA (1993). « The Effect of Errors in Means, Variances and Covariances on Optimal Portfolio Choice ». In : *Journal of Portfolio Management* 19.2, p. 6-11. DOI : [10.3905/jpm.1993.409440](https://doi.org/10.3905/jpm.1993.409440).
- CORIAT, Benjamin et Eric BENHAMOU (2025). *HARLF : Hierarchical Reinforcement Learning and Lightweight LLM-Driven Sentiment Integration for Financial Portfolio Optimization*. IJCAI 2025 - FinLLM Workshop, Guangzhou, China, August 28, 2025. arXiv :2507.18560. URL : <https://arxiv.org/abs/2507.18560>.
- DU, Juan (2022). « Mean–variance portfolio optimization with deep learning based-forecasts for cointegrated stocks ». In : *Expert Systems with Applications* 201, p. 117005. DOI : [10.1016/j.eswa.2022.117005](https://doi.org/10.1016/j.eswa.2022.117005).
- DU, Xin, Jinjian ZHAI et Koupin LV (2016). « Algorithm trading using Q-learning and recurrent reinforcement learning ». In : *Positions* 1.
- FAMA, Eugene F. et Kenneth R. FRENCH (1993). « Common Risk Factors in the Returns on Stocks and Bonds ». In : *Journal of Financial Economics* 33, p. 3-56. DOI : [10.1016/0304-405X\(93\)90023-5](https://doi.org/10.1016/0304-405X(93)90023-5). URL : [https://doi.org/10.1016/0304-405X\(93\)90023-5](https://doi.org/10.1016/0304-405X(93)90023-5).
- (2015). « A five-factor asset pricing model ». In : *Journal of Financial Economics* 116.1, p. 1-22. DOI : [10.1016/j.jfineco.2014.10.010](https://doi.org/10.1016/j.jfineco.2014.10.010). URL : <https://doi.org/10.1016/j.jfineco.2014.10.010>.

- FOKOU, Raoul (2006). *Mesure du risque de marché d'un portefeuille de type Actions (Value-At-Risk, Value-At-Risk Conditionnelle)*. Mémoire d'actuariat. Euro-Institut d'Actuariat Jean Dieudonné (EURIA).
- GALBRAITH, John Kenneth (1955). *The Great Crash 1929*. Boston : Houghton Mifflin.
- GAO, Ziming et al. (2020). « Application of Deep Q-Network in Portfolio Management ». In : *arXiv preprint arXiv :2003.06365*. URL : <https://arxiv.org/abs/2003.06365>.
- HAARNOJA, Tuomas et al. (2018). « Soft Actor-Critic : Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor ». In : *arXiv preprint arXiv :1801.01290*. URL : <https://arxiv.org/abs/1801.01290>.
- HACHAÏCHI, Yassine et Amir LANWER (2024). *Benchmarking Reinforcement Learning (RL) Algorithms for Portfolio Optimization*. Preprint. DOI : [10.13140/RG.2.2.20482.70085](https://doi.org/10.13140/RG.2.2.20482.70085). URL : <https://doi.org/10.13140/RG.2.2.20482.70085>.
- HAN, Yingwei et Ping LI (2020). « Robust portfolio selection using vine copulas ». In : *SSRN Electronic Journal*. Published January 2020. DOI : [10.2139/ssrn.3711266](https://papers.ssrn.com/abstract=3711266). URL : <https://papers.ssrn.com/abstract=3711266>.
- HARVEY, Campbell R. et Akhtar SIDDIQUE (2000). « Conditional Skewness in Asset Pricing Tests ». In : *Journal of Finance* 55.3, p. 1263-1295. DOI : [10.1111/0022-1082.00247](https://doi.org/10.1111/0022-1082.00247). URL : <https://doi.org/10.1111/0022-1082.00247>.
- HOLLAND, John H. (1992). *Adaptation in Natural and Artificial Systems : An Introductory Analysis with Applications to Biology, Control, and Artificial Intelligence*. 2nd Edition, originally published 1975. The MIT Press. ISBN : 9780262275552. DOI : [10.7551/mitpress/1090.001.0001](https://doi.org/10.7551/mitpress/1090.001.0001).
- HOWARD, Ronald A. (1960). *Dynamic Programming and Markov Processes*. Published jointly by MIT Press and John Wiley & Sons. Cambridge, MA et New York, NY : The Technology Press of the Massachusetts Institute of Technology et John Wiley & Sons, Inc. URL : <https://doi.org/10.7551/mitpress/10808.001.0001>.
- HWANG, Soosung et Stephen SATCHELL (1999). « Modelling Emerging Market Risk Premia Using Higher Moments ». In : *International Journal of Finance and Economics* 4.4, p. 271-296. DOI : [10.1002/\(SICI\)1099-1158\(199910\)4:4<271::AID-IJFE110>3.0.CO;2-M](https://doi.org/10.1002/(SICI)1099-1158(199910)4:4<271::AID-IJFE110>3.0.CO;2-M). URL : [http://dx.doi.org/10.1002/\(SICI\)1099-1158\(199910\)4:4<271::AID-IJFE110>3.0.CO;2-M](http://dx.doi.org/10.1002/(SICI)1099-1158(199910)4:4<271::AID-IJFE110>3.0.CO;2-M).
- JANG, Junkyu et NohYoon SEONG (2023). « Deep reinforcement learning for stock portfolio optimization by connecting with modern portfolio theory ». In : *Expert Systems with Applications* 228, p. 119556. DOI : [10.1016/j.eswa.2023.119556](https://doi.org/10.1016/j.eswa.2023.119556). URL : <https://doi.org/10.1016/j.eswa.2023.119556>.
- JIANG, Yifu, Jose OLMO et Majed ATWI (2024). « Deep Reinforcement Learning for Portfolio Selection ». In : *Global Finance Journal*. *Corresponding author : Jose Olmo. DOI : [10.1016/j.gfj.2024.101016](https://doi.org/10.1016/j.gfj.2024.101016).
- KAKOURIS, Iakovos et Berc RUSTEM (2014). « Robust portfolio optimization with copulas ». In : *European Journal of Operational Research* 239.2, p. 581-590. DOI : [10.1016/j.ejor.2013.12.022](https://doi.org/10.1016/j.ejor.2013.12.022).
- KRAUS, Alan et Robert H. LITZENBERGER (1976). « Skewness Preference and the Valuation of Risk Assets ». In : *The Journal of Finance* 31.4, p. 1085-1100. DOI : [10.2307/2326275](https://doi.org/10.2307/2326275). URL : <https://doi.org/10.2307/2326275>.
- LINTNER, John (1965). « The Valuation of Risk Assets and the Selection of Risky Investments in Stock Portfolios and Capital Budgets ». In : *The Review of Economics and Statistics* 47.1, p. 13-37. DOI : [10.2307/1924119](https://doi.org/10.2307/1924119). URL : <https://www.jstor.org/stable/1924119>.
- MAFUSALOV, Alexandre et Stan URYASEV (2018). « Buffered Probability of Exceedance : Mathematical Properties and Optimization ». In : *SIAM Journal on Optimization* 28.2,

- p. 1077-1103. DOI : [10.1137/15M1042644](https://doi.org/10.1137/15M1042644). URL : <https://doi.org/10.1137/15M1042644>.
- MANDELBROT, Benoit B. (1963). « The Variation of Certain Speculative Prices ». In : *The Journal of Business* 36.4, p. 394-419. URL : <http://www.jstor.org/stable/2350970>.
- MANJUNATHA, B. et al. (déc. 2024). « Trivariate-ARMA–GARCH Type–Vine Copula Model for Time Series Forecasting ». In : *Communications in Statistics - Simulation and Computation*. Published online on 5 December 2024. DOI : [10.1080/03610918.2024.2433495](https://doi.org/10.1080/03610918.2024.2433495). URL : <https://doi.org/10.1080/03610918.2024.2433495>.
- MARKOWITZ, Harry (1952). « Portfolio Selection ». In : *The Journal of Finance* 7.1, p. 77-91. DOI : [10.2307/2975974](https://doi.org/10.2307/2975974).
- MARKOWITZ, Harry M. (1959). *Portfolio Selection : Efficient Diversification of Investments*. New Haven : Yale University Press. URL : <https://www.jstor.org/stable/j.ctt1bh4c8h>.
- MERTON, Robert C. (1980). « On Estimating the Expected Return on the Market : An Exploratory Investigation ». In : *Journal of Financial Economics* 8, p. 323-361. DOI : [10.1016/0304-405X\(80\)90007-0](https://doi.org/10.1016/0304-405X(80)90007-0). URL : [https://doi.org/10.1016/0304-405X\(80\)90007-0](https://doi.org/10.1016/0304-405X(80)90007-0).
- MICHAUD, Richard O. (1989). « The Markowitz Optimization Enigma : Is “Optimized” Optimal ? » In : *Financial Analysts Journal* 45.1, p. 31-42. DOI : [10.2469/faj.v45.n1.31](https://doi.org/10.2469/faj.v45.n1.31). URL : <https://doi.org/10.2469/faj.v45.n1.31>.
- MOODY, John et Matthew SAFFELL (1998). « Reinforcement Learning for Trading ». In : *Advances in Neural Information Processing Systems*. Sous la dir. de Michael KEARNS, Sara SOLLA et David COHN. T. 11. MIT Press. URL : https://proceedings.neurips.cc/paper_files/paper/1998/file/4e6cd95227cb0c280e99a195be5f6615-Paper.pdf.
- NEUMANN, John von et Oskar MORGENSTERN (1944). *Theory of Games and Economic Behavior*. Princeton, NJ : Princeton University Press.
- OLANREWAJU, Ayobami Gabriel, Olayinka Hammed SIKIRU et David FAWEHINMI (2025). « Artificial Intelligence in Quantitative Finance : Leveraging Deep Learning for Smarter Portfolio Management and Asset Allocation ». In : *International Journal of Research* 12.4. Creative Commons Attribution 4.0 International, p. 422-458. DOI : [10.5281/zenodo.15323194](https://doi.org/10.5281/zenodo.15323194).
- OLANREWAJU, Ayobami Gabriel et al. (2025). « AI-Driven Adaptive Asset Allocation : A Machine Learning Approach to Dynamic Portfolio ». In : *International Journal of Research in Finance and Management* 8.1, p. 320-332. DOI : [10.33545/26175754.2025.v8.i1d.451](https://doi.org/10.33545/26175754.2025.v8.i1d.451).
- PAREEK, Savita et Sujit K. GHOSH (2025). *Semiparametric Dynamic Copula Models for Portfolio Optimization*. Preprint. arXiv :2504.12266v1. URL : <https://arxiv.org/abs/2504.12266v1>.
- PARK, Hyungjun, Min Kyu SIM et Dong Gu CHOI (2019). « An intelligent financial portfolio trading strategy using deep Q-learning ». In : *arXiv preprint arXiv :1907.03665*. URL : <https://arxiv.org/abs/1907.03665>.
- PENDHARKAR, Parag C. et Patrick CUSATIS (2018). « Trading financial indices with reinforcement learning agents ». In : *Expert Systems with Applications* 103, p. 1-13. DOI : [10.1016/j.eswa.2018.02.032](https://doi.org/10.1016/j.eswa.2018.02.032).
- PHILIPPE ARTZNER Freddy Delbaen, Jean-Marc Eber et David HEATH (1999). « Coherent Measures of Risk ». In : *Mathematical Finance* 9.3, p. 203-228. DOI : [10.1111/1467-9965.00068](https://doi.org/10.1111/1467-9965.00068). URL : <https://doi.org/10.1111/1467-9965.00068>.

- RAMBOUR, Cédric (2023). *Apprentissage par renforcement : cadre général et programmation dynamique*. Support de cours, CNAM. URL : <https://cedric.cnam.fr/vertigo/cours/RCP211/docs/courseRL1.pdf>.
- RICHARD, Nicolas Jean René (2021). « Intelligence Artificielle appliquée à la gestion de portefeuille ». Dir. de mémoire : Istvan Nagy. Mémoire de bachelor. Genève, Suisse : Haute école de gestion de Genève (HEG-GE), p. 72. URL : <https://sonar.ch/global/documents/315004>.
- ROCKAFELLAR, R. Tyrrell et Stanislav URYASEV (2000). *Optimization of Conditional Value-at-Risk*. Rapp. tech. Working paper. University of Washington. URL : <https://sites.math.washington.edu/~rtr/papers/rtr179-CVaR1.pdf>.
- ROLL, Richard (1988). « The International Crash of October 1987 ». In : *Financial Analysts Journal* 44.5, p. 19-35.
- SEGERS, Johan, Masaaki SIBUYA et Hideatsu TSUKAHARA (2016). « The Empirical Beta Copula ». In : *arXiv preprint arXiv :1607.04430*. Published November 21, 2016. URL : <https://arxiv.org/abs/1607.04430>.
- SEMENOV, Mikhail et Daulet SMAGULOV (2017). « Portfolio Risk Assessment using Copula Models ». In : *arXiv preprint arXiv :1707.03516*. arXiv : 1707.03516 [q-fin.RM]. URL : <https://arxiv.org/abs/1707.03516>.
- SHARPE, William F. (1964). « Capital Asset Prices : A Theory of Market Equilibrium under Conditions of Risk ». In : *The Journal of Finance* 19.3, p. 425-442. DOI : 10.2307/2977928. URL : <https://www.jstor.org/stable/2977928>.
- SILVERMAN, B. W. (1986). *Density Estimation for Statistics and Data Analysis*. London : Chapman & Hall. DOI : 10.1007/978-1-4899-3324-9.
- SKLAR, Abe (1959). « Fonctions de répartition à N dimensions et leurs marges ». In : *Annales de l'ISUP* 8.3, p. 229-231. URL : <https://hal.science/hal-04094463>.
- SOMMER, Philipp Emanuel Maria (avr. 2022). « Estimation and Backtesting of the Expected Shortfall and Value at Risk using Vine Copulas : An Unconditional and Conditional Rolling Window Approach ». Thesis for the attainment of the academic degree Master of Science (M.Sc.) Mém. de mast. Munich : Technical University of Munich, Department of Mathematics. URL : <https://mediatum.ub.tum.de/doc/1658240/1658240.pdf>.
- SZEGÖ, Giorgio (2002). « Measures of Risk ». In : *Journal of Banking & Finance* 26, p. 1253-1272. DOI : 10.1016/S0378-4266(02)00262-5. URL : [https://doi.org/10.1016/S0378-4266\(02\)00262-5](https://doi.org/10.1016/S0378-4266(02)00262-5).
- Waldata — *Indicateurs techniques pour le trading* (2025). Site web. URL : <https://www.waldata.fr/indicateurs>.
- WATKINS, C. J. C. H. et Peter DAYAN (1992). « Q-Learning ». In : *Machine Learning* 8.3-4, p. 279-292. DOI : 10.1007/BF00992698. URL : <https://doi.org/10.1007/BF00992698>.
- WILLIAMS, Ronald J. (1992). « Simple Statistical Gradient-Following Algorithms for Connectionist Reinforcement Learning ». In : *Machine Learning* 8.3-4, p. 229-256. DOI : 10.1007/BF00992696. URL : <https://doi.org/10.1007/BF00992696>.
- ZHU, Shushang et Masao FUKUSHIMA (2009). « Worst-Case Conditional Value-at-Risk with Application to Robust Portfolio Management ». In : *Operations Research* 57.5, p. 1155-1168. DOI : 10.1287/opre.1080.0684.

Table des matières

DEDICACE	iii
Remerciements	iv
Résumé	vii
Abstract	viii
Introduction	1
1 Cadre théorique de l'étude	5
1.1 Introduction	5
1.2 Clarification conceptuelle	6
1.2.1 Définitions	6
1.3 Revue de Litterature	22
1.4 Conclusion	25
2 Cadre méthodologique de l'étude	27
2.1 Introduction	28
2.2 Outils et données utilisés	28
2.2.1 Outils utilisés	28
2.2.2 Données utilisées	28
2.3 Méthodes	29
2.3.1 Copule	29
2.3.2 Sélection des titres pour la constitution du portefeuille	31
2.3.3 Apprentissage par renforcement	34
2.3.4 Modèles de référence (benchmarks)	38
2.3.5 Protocole d'entraînement, validation et test	39
2.4 Conclusion	40
3 Résultats et Discussion	41
3.1 Introduction	42
A Annexes	43
A.1 Démonstrations mathématiques complémentaires	43
A.1.1 Démonstration de l'équation de Bellman pour la fonction de valeur	43
A.1.2 Démonstration de l'équation de Bellman pour la fonction d'action-valeur	45
A.2 Modèles	46
A.2.1 Modèle ARMA	46
A.2.2 Modèle GJR-GARCH	46
A.2.3 SAC(Soft Actor Critic)	47
A.3 Tests statistiques	53

A.3.1	Test de stationnarité des rendements	53
A.3.2	Test de Ljung-Box	54
A.3.3	Test ARCH d'Engle	54
A.4	Indicateurs techniques	54
A.5	Résultats	56

TABLE DES FIGURES

1.1	Fonction de valeur d'état $V_\pi(s)$ (extrait de (RAMBOUR, 2023))	12
1.2	Fonction de valeur d'action $Q_\pi(s, a)$ (extrait de (RAMBOUR, 2023))	13
1.3	Fonction de valeur état action $V_\pi(s, a)$ (extrait de (RAMBOUR, 2023))	14

LISTE DES TABLEAUX

1.1	Types d'apprentissage automatique	9
A.1	Résumé des tests de stationnarité (ADF et KPSS)	54
A.2	Hypothèses et règle de décision du test de Ljung–Box	54
A.3	Hypothèses et règle de décision du test d'Engle (ARCH LM test)	54
A.4	Résultats des tests de stationnarité (ADF et KPSS) pour l'ensemble des titres	56
A.5	Résultats des tests de stationnarité (ADF et KPSS) pour l'ensemble des titres	57

